

Matematično-fizikalni praktikum: Naključni sprehodi

Žan Ambrožič (28231062)

20. oktober 2025

1 Naloga

Napravi računalniško simulacijo dvorazsežne naključne hoje za **polete in sprehode**. Začni vedno v izhodišču ($x = y = 0$), nato pa določi naslednjo lego tako, da naključno izbereš smer koraka in statistično neodvisno od te izbire še njegovo dolžino, torej

$$\begin{aligned}x &\leftarrow x + l \cos \phi, \\y &\leftarrow y + l \sin \phi,\end{aligned}$$

kjer je ϕ enakomerno naključno porazdeljen po intervalu $[0, 2\pi]$, dolžina koraka l pa naj bo porazdeljena v skladu s potenčno obliko $p(l) \propto l^{-\mu}$. Dolžine l_i je v tem primeru potrebno generirati po verjetnostni porazdelitvi $w(l) \sim p(l)$. Za izračun algoritma je osnova naslednja formula:

$$\int_a^l w(t) dt = \rho \cdot \int_a^b w(t) dt, \quad (1)$$

ki jo je potrebno rešiti in iz nje izraziti spremenljivko l . Tu je ρ (psevdo-)naključno število na intervalu $[0, 1]$ ter je $[a, b]$ relevantni interval vzorčenja. Za nekatere porazdelitve je izračun preprost, npr $w(t) = \frac{1}{\tau} e^{-\frac{t}{\tau}}$ nam da kar:

$$l = -\tau \ln(1 - \rho). \quad (2)$$

2 Uvod

Naključni sprehodi so vrsta gibanja, pri katerem v velikem številu korakov napredujemo iz izhodišča v neko končno lego, tako da se parametri vsakega naslednjega koraka sproti naključno določajo. Običajni zgled je Brownovo gibanje (difuzija) drobnih delcev barvila po mirujoči homogeni tekočini, kjer je spočetka barvilo zbrano v izhodišču. "Težišče" barvila $\langle x(t) \rangle$ v povprečju ostane v izhodišču, razen če v tekočini vzpostavimo kako anizotropijo (na primer v dveh razsežnostih z vsiljeno rotacijo). "Razmazanost" po dolgem času je sorazmerna s časom,

$$\sigma^2(t) \equiv \langle x^2(t) \rangle - \langle x(t) \rangle^2 = 2Dt.$$

Sorazmernostni koeficient je običajna difuzijska konstanta, priča smo normalni difuziji. Ta rezultat izhaja iz centralnega limitnega teorema (CLT), ki izraža, da je rezultatna porazdelitev končnih leg pri difuziji porazdeljena normalno (Gauss), če so le povprečni časi med koraki in povprečni kvadrati dolžin korakov končni.

Zanimiveje je opazovati naključne sprehode, pri katerih dovolimo nadpovprečno dolge korake. Verjetnostno gostoto porazdelitve po dolžinah posameznih korakov parametrizirajmo v potenčni obliki

$$p(l) \propto l^{-\mu}, \quad (3)$$

kjer naj bo $1 < \mu < 3$. Tedaj postane drugi moment porazdelitve

$$\langle l^2 \rangle = \int l^2 p(l) dl$$

neskončen. Govorimo o anomalni difuziji, prisotni pri celi družini kinematičnih distribucij dolžin poti z "debelimi repi".

Ustrezno sliko naključnega gibanja, povezanega s temi dolgimi koraki, lahko interpretiramo na dva načina:

- Lévyjev pobeg oz. polet (*flight*), implicira, da vsak korak iz porazdelitve (3) traja enako dolgo, medtem ko se hitrost gibanja med koraki (divje) spreminja.
- Lévyjev sprehod (*walk*), ki interpretira korak iz porazdelitve (3) kot gibanje s konstantno hitrostjo in tako koraki trajajo različno dolgo časa (dolžina koraka je sorazmerna s časom).

Slednja interpretacija bolj ustreza fizikalni sliki naključnega gibanja delca skozi snov, medtem ko se prva interpretacija uporablja v drugačnih aplikacijah.

Vse naloge lahko obravnavamo za obe interpretaciji, pobegov in sprehodov. V prvem primeru (pobeg, *flight*) je pretečeni čas direktno sorazmeren s številom korakov, v drugem primeru (sprehod, *walk*) pa je pretečeni čas sorazmeren z vsoto dolžine korakov.

Pri anomalni difuziji razmazanost (varianca) velike množice končnih leg naključnih Lévyjevih **sprehodov (walks)** narašča z drugačno potenco časa. Velja $\sigma^2(t) \sim t^\gamma$, kjer je

$$\begin{aligned} 1 < \mu < 2, & \quad \gamma = 2 & \text{(balistični režim),} \\ 2 < \mu < 3, & \quad \gamma = 4 - \mu & \text{(super-difuzivni režim),} \\ \mu > 3, & \quad \gamma = 1 & \text{(normalna difuzija).} \end{aligned}$$

Za $\mu = 2$ pričakujemo $\sigma^2(t) \sim t^2 / \ln t$, za $\mu = 3$ pa $\sigma^2(t) \sim t \ln t$.

Slika je nekoliko drugačna pri opazovanju naključnih Lévyjevih **poletov (flights)**. Spet vzamemo zvezo $\sigma^2(t) \sim t^\gamma$ in dobimo odvisnosti

$$\begin{aligned} 1 < \mu < 3, & \quad \gamma = \frac{2}{\mu - 1} & \text{(super-difuzivni režim),} \\ \mu > 3, & \quad \gamma = 1 & \text{(normalna difuzija).} \end{aligned}$$

Pri $\mu = 2$ očitno pričakujemo $\sigma^2(t) \sim t^2$, torej balistični režim.

3 Reševanje

Zaradi velikega števila operacij v **for** zankah tokrat **Python** kljub možnosti paralelizma ni najboljša izbira, saj teče prepočasi. Hitrejše možnosti ponujajo jeziki, ki se v naprej prevedejo v strojno kodo, kot primeren se izkaže **C#**, ki izvede simulacije skoraj dva velikostna reda hitreje (na enakem številu jeder). Proces je smiselno sprogramirati tako, da poteka paralelno in da procesi kasnejših faz ne čakajo prejšnjih – to lahko dosežemo tako, da za vsak μ oz. kombinacijo μ in ν naredimo svoj proces, ki pokriva vse od začetka do konca (najprej opravi vse simulacije, izračuna mediane, preračuna vrednosti za osi, poišče najboljšo premico in vrne njene parametre skupaj z oceno napake), nato pa dobljene vrednosti lahko uporabimo direktno za risanje grafov. Tak način tudi varčuje s pomnilnikom in predvsem prihrani čas morebitnega pisanja/branja vmesnih rezultatov na disk (sploh če bi shranjevali lokacijo v odvisnosti od časa za vsak delec posebej). Velja še omeniti, da vnaprej izberemo čase, pri katerih gledamo lego. Ker bomo prilegali premico na logaritemskem grafu, je čase smiselno izbrati eksponentno, s čimer zagotovimo kolikor toliko enakomerne intervale med točkami (vsaj za večje čase in korake, ko se sprememba zaradi zaokroževanja na najbližje celo število praktično ne pozna več).

3.1 Generator naključnih dolžin po distribuciji

Osnovni vgrajen generator naključnih števil nam vrača realna števila na intervalu $[0, 1)$. Generiranje naključnih kotov je zato enostavno, saj naključno število le pomnožimo z 2π . Dolžine poletov pa zahtevajo dodatno knjižnico ali pa malo matematike: najprej moramo porazdelitev normalizirati, za kar potrebujemo minimalno dolžino koraka (l_0):

$$\int_{l_0}^{\infty} C l^{-\mu} dl = \frac{C l_0^{1-\mu}}{\mu - 1}, \quad (4)$$

sledi

$$p(l) = (\mu - 1) l_0^{\mu-1} l^{-\mu}. \quad (5)$$

Sedaj lahko določimo komulativno porazdelitev, ki naj bo uniformna:

$$F(l) = \int_{l_0}^l p(x) dx = 1 - \left(\frac{l}{l_0} \right)^{1-\mu} = u; \quad u \sim U(0, 1) \quad (6)$$

Od tod dobimo dolžino koraka iz naključno generiranega števila:

$$l = l_0(1 - u)^{\frac{1}{1-\mu}}. \quad (7)$$

Za l_0 lahko vzamemo kar 1.

3.2 Mediana absolutne deviacije

Zaradi stabilnosti (predvsem pri anomalni difuziji varianca slabo oceni razpršenost delcev) raje kot varianco uporabljamo MAD, ki ji izračunamo kot:

$$\text{MAD}(a) = \text{Mediana}(|a - \text{Mediana}(a)|). \quad (8)$$

V našem primeru za a vzamemo lego delca (x, y) . Ker za dovolj veliko število ponovitev pričakujemo, da je lega razporejena okoli izhodišča, je notranja mediana kar $(0, 0)$, tako da v resnici računamo le mediano absolutne vrednosti lege, ki pa je kar oddaljenost od izhodišča:

$$\text{MAD}(a) = \text{Mediana}\left(\sqrt{x^2 + y^2}\right). \quad (9)$$


3.3 Interpolacija pri sprehodih

Ker sprehode simuliramo na enak način kot polete, ne težko primerjamo distribucije ob istih trenutkih, saj so vsi koraki različno dolgi. Zaradi preprostosti lahko vzamemo enotsko hitrost (enačimo enoto časa in enoto poti). Problem rešimo z interpolacijo med "pristankoma" pred in po želenem času:


$$\mathbf{r}(t) = \mathbf{r}_1 + (\mathbf{r}_2 - \mathbf{r}_1) \frac{t - t_1}{t_2 - t_1}. \quad (10)$$

4 Rezultati


4.1 Distribucija oddaljenosti




Slika 1: 10000 korakov pri $\mu = 2$ (koraki, krajši od 10 enot niso narisani, premiki so izvedeni).



Slika 2: 10000 korakov pri $\mu = 3$ (koraki, krajši od 3 enot, niso narisani, premiki so izvedeni).



Graf 1: Distribucija oddaljenosti po 1000 korakih za $\mu = 2$. Rdeča črta označuje mediano. $N = 10000$.




Graf 2: Distribucija oddaljenosti po 1000 korakih za $\mu = 3$. Rdeča črta označuje mediano. $N = 10000$.

Distribuciji pokazeta dolge repe, ki bi kljub majhenmu številu močno vplivali na varianco (integral divergira).

4.2 Določanje γ

Upoštevamo, da velja $\sigma^2 \sim t^\gamma$, ker je za normalno distribucijo $\text{MAD}^2 = 0,454\,94\sigma^2$




Graf 3: Primer iskanja γ za $\mu = 1,5$, sprehod brez čakanja, rezultat: $\gamma = 1,935 \pm 0,008$.


4.2.1 Posebna primera $\mu = 2$ in $\mu = 3$

Za posebna primera veljata enačbi:

$$\sigma^2 \sim \frac{t^\gamma}{\ln(t)}, \quad \sigma^2 \sim t^\gamma \cdot \ln(t). \quad (11)$$




Graf 4: Določanje parametrov pri $\mu = 2$. Za potenčno funkcijo dobimo eksponent $1,811 \pm 0,009$, za sestavljeno pa $1,906 \pm 0,009$.



Graf 5: Določanje parametrov pri $\mu = 3$. Za potenčno funkcijo dobimo eksponent $1,133 \pm 0,007$, za sestavljeno pa $1,037 \pm 0,008$.


Medtem ko se grafa obeh funkcij praktično prekrivata, dobimo različne ocene parametra γ . S enačbama za posebna primera dobimo oceni γ , znatno boljši od ocene s potenčno enačbo: pri $\mu = 2$ se relativno odstopanje zmanjša z 19% na 9%, medtem ko se pri $\mu = 3$ zmanjša s 13% na 3,7% (na časovnem intervalu do $6 \cdot 10^4$ časovnih enot).

4.2.2 Odvisnost $\gamma(\mu)$ za polete in sprehode



Graf 6: Naključni poleti v odvisnosti od μ , 10000 korakov, 10000 ponovitev.

Na grafu 6 je zaradi boljše predstave (in tudi zaradi linearne teoretične napovedi, glede na podano teoretično odvisnost parametra pri super-difuziji) risana obratna vrednost za γ . Simulirane točke so na dveh različnih režimih – območje super-difuzije ($\mu \in [1, 3]$) ter normalne difuzije ($\mu \in [3, 4]$). Zlasti za nižje μ se simulirane vrednosti zelo dobro ujemajo s teoretičnimi napovedmi. Na območju normalne difuzije ne velja več potenčna odvisnost, kar je eden od možnih razlogov za odstopanje od teoretične napovedi.



Graf 7: Naključni sprehodi v odvisnosti od μ , do 50000 korakov (ali 10^5 časovnih enot), 10000 ponovitev.

Simulirane točke so na treh različnih režimih – območje balistične difuzije ($\mu \in [1, 2]$), super-difuzije ($\mu \in [2, 3]$) ter normalne difuzije ($\mu \in [3, 4]$). Razhod med simulacijo in teorijo je pričakovano največji za prej omenjena posebna primera $\mu = 2$, $\mu = 3$, najboljše ujemanje pa dobimo za $\mu \rightarrow 1$.

4.3 Mirovanje med sprehodi


Če upoštevamo še "trapping time" (mirovanje med zaporednimi odseki sprehodov), ki je porazdeljen po enaki verjetnosti gostoti kot dolžina korakov (le da μ nadomestimo z novim neodvisnim parametrom $\nu \in (1, 2]$), se nam tudi režimi difuzije spremenijo: za super-difuzijo velja $\gamma = 2 + \nu - \mu$, dobimo pa novo območje sub-difuzije, kjer velja $\gamma = \nu - 1$. Na grafu 8 so območja različna za različne vrednosti ν : dokler $\gamma = 2$, smo v režimu balistične difuzije, na območju, kjer se γ spreminja z μ , smo v režimu super-difuzije, za višje μ pa v režimu sub-difuzije. Ponovno

opazimo, da se simulacija najboljše ujema s teoretičnimi napovedmi za $\mu \rightarrow 1$ pri vseh vrednostih ν , opazimo pa tudi zvezno odvisnost $\gamma(\nu)$. Verjetno tudi v tem primeru obstajajo kakšni izrazi za boljše približke γ za posebne primere (predvsem za mejo med balistično in super-difuzijo, kjer je odstopanje največje). Nekoliko bolje je pri večjih vrednostih.

5 Zaključek

V tej nalogi so opisani rezultati simulacij Lévyjevih poletov in sprehodov, kjer smo ugotavljali, kako dobro se (statistično) simulacije ujema s teoretičnimi napovedmi.

Možne nadaljne izboljšave bi bile, da bi preizkusili še več statističnih cenilk, ki so za normalno distribucijo podobne varianci ter ugotovili, v katerih primerih je posamezna najboljša. Druga možna izboljšava bi bila uporaba še morebitnih dodatnih formul za posebne primere (poleg 11, predvsem če obstajajo takšne, ki veljajo na intervalih parametra, ne le v eni točki). Še ena možnost nadaljne raziskave bi bila ugotavljanje odvisnosti γ z grafa 8 od razmerja med najmanjšim korakom in najmanjšim čakalnim časom, ki ju določimo v distribuciji 7 – v našem primeru sta bili obe nastavljeni na 1, dovolj pa bi bilo spreminjati le eno, saj na obliko lahko vpliva le razmerje med njima (vsa prileganja za γ so bila narejena za proporcionalnost in nikjer nismo uporabili konstantnega predfaktorja, ki je odvisen le od skale švetašimulacije, ki ga določimo ravno z najmanjšim korakom).



Graf 8: Naključni sprehodi s čakanjem (za različne vrednosti ν) v odvisnosti od μ , do 50000 korakov (ali 10^5 časovnih enot), 1000 ponovitev.