Modelska analiza 1: Populacijski modeli

Žan Ambrožič (28262032)

25. oktober 2026

1 Epidemija

1.1 Osnovni model

Oglejmo si preprost model epidemije: dovzetni (D) lahko zbolijo za boleznijo, če je del populacije že bolan (B), bolni pa s časom ozdravijo in po preboleli bolezni postanejo imuni (I). Eden od modelov za statistično populacijo (ne gledamo posameznikov, tako kot pri radioaktivnih razpadih gledamo statistično število jeder in ne posameznih razpadov) je:

$$\dot{D} = -\alpha DB \tag{1}$$

$$\dot{B} = +\alpha DB - \beta B \tag{2}$$

$$\dot{I} = +\beta B \tag{3}$$

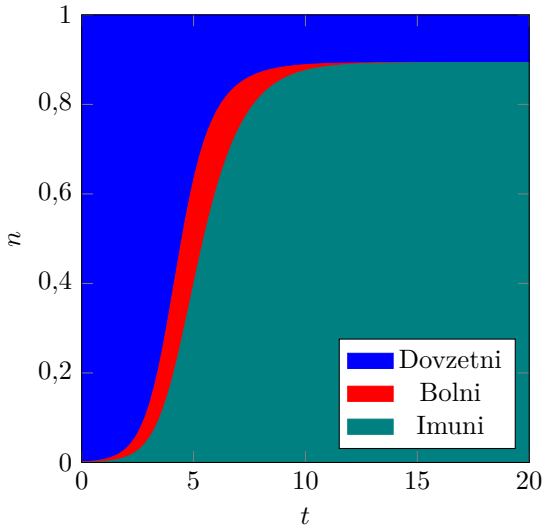
Brezdimenzijske spremenljivke: $t \to \beta t$, $k = \alpha/\beta$:

$$\dot{d} = -kdb \tag{4}$$

$$\dot{b} = kdb - b \tag{5}$$

$$\dot{i} = b \tag{6}$$

Postavimo še predpostavko o ohranitvi populacije $d + b + i = 1$. Opomba: odvoda po časih nista ekvivalentna med prvotnim in brezdimenzijskim sistemom enačb – v brezdimenzijski obliki je čas skaliran s faktorjem β, vendar zaradi preprostosti pišemo tudi odvod po tem času s piko, saj prvotne enačbe v nadaljevanju nikjer ne bomo omenjali. Parameter k tako ni odvisen le od prenosljivosti bolezni, temveč tudi od časa, potrebnega za okrevanje.

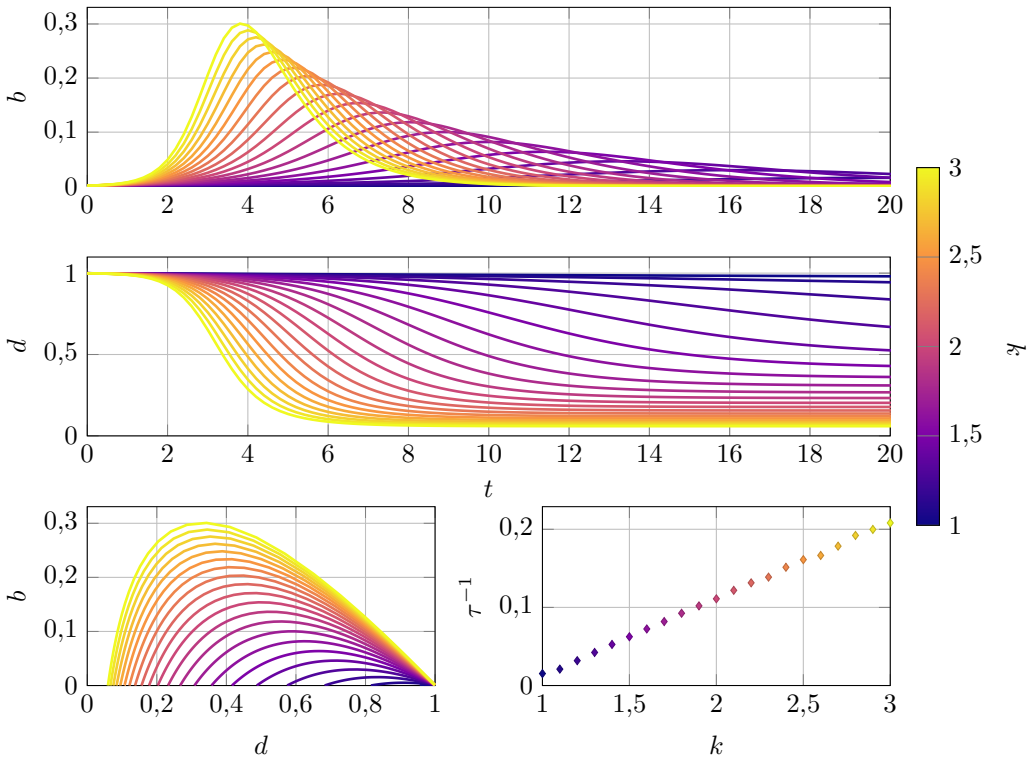


Graf 1: Primer epidemije s parametrom $k = 2{,}5$ in začetnim deležem bolnih 10^{-3}.

Hitro prepoznamo ravnovesno stanje $b = 0$ – če ni bolnih, se bolezen ne širi, vsi so zdravi ali imuni. Izračunajmo še Jacobijan in vstavimo ravnovesno stanje:

$$\begin{bmatrix} -kb & -kd & 0 \\ kb & kd-1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \quad \rightarrow \quad \begin{bmatrix} 0 & -kd & 0 \\ 0 & kd-1 & 0 \\ 0 & 1 & 0 \end{bmatrix}. \tag{7}$$

Lastne vrednosti so dvakrat 0 in enkrat $kd - 1$, ki določa stabilnost: če je $kd - 1 < 0$, je ravnovesno stanje stabilno, sicer pa ne; tj. preveč dovzetnih ljudi oz. preveč prenosljiva (in/ali počasi ozdravljiva) bolezen povzroči epidemijo (število bolnih bo naraščalo, dokler ne bo upadlo število dovzetnih). Razmislek seveda velja za začetni pogoj, ko je število bolnih majhno (blizu 0), ne velja za populacijo z velikim deležem bolnih, saj npr. če je na začetku simulacije že polovica populacije okužene, bo (razen za zelo nalezljivo bolezen) število bolnih le še upadalo. Če torej predpostavimo, da je $d(0) \approx 1$, bo kritična vrednost $k = 1$. V začetku, ko je $b \ll 1$ in $d \approx 1$, še lahko aproksimiramo eksponentno rast števila bolnih $b(t) \sim e^{(k-1)t}$, karakteristična časovna skala je tako $\tau \sim 1/(k-1)$. Karakteristični čas bomo definirali kot čas, ko delež bolnih pade na 10% svoje začetne vrednosti (glede na končno vrednost). Zakaj začetni delež bolnih ni tako pomemben? Če je k podkritičen, bo število bolnih približno eksponentno padalo, torej manjši delež bolnih v približku pomeni le premik v kasnejši trenutek prvega primera in obratno za malo večji delež bolnih (še vedno predpostavljamo $b(0) \ll 1$, posledično tudi $i(t) \ll 1$). V primeru nadkritičnega k pa bo število bolnih na začetku eksponentno naraščalo, imunih pa bo v tej fazi še zelo malo, zato lahko naredimo podoben razmislek glede začetnega pogoja kot premika v času po stanjih z nekim drugim začetnim pogojem. To pomeni, da tudi višina vrha epidemije (največje število sočasno bolnih) v tem modelu ni odvisna od začetnega pogoja, ampak le od parametra k. Z drugimi besedami – na faznem diagramu se postavimo v točko na eni od črt.



Graf 2: Število bolnih in dovzetnih v odvisnosti od časa, fazni diagram in odvisnost karakterističnega časa od k za nadkritično populacijo $k \geqslant 1$.

Pričakovano, večji kot je parameter k, večji del populacije zboli in vrh je višji, hkrati pa je epidemija hitrejša. Analizo lahko peljemo še nekoliko dlje: fazni diagram lahko opišemo, če delimo prvi dve enačbi sistema:

$$\frac{\dot{b}}{\dot{d}} = \frac{1}{kd} - 1 = \frac{\mathrm{d}b}{\mathrm{d}d} \quad \rightarrow \quad b = -d + \frac{1}{k}\ln(d) + C \quad \rightarrow \quad b = b_0 + d_0 - d + \frac{1}{k}\ln\left(\frac{d}{d_0}\right). \tag{8}$$

Od tod lahko izluščimo tako največje število bolnih (ko populacija doseže kritično vrednost $d = 1/k$ in število obolelih

začne padati) kot tudi končno število imunih oz. preostalih dovzetnih. Spomnimo, na koncu ni več bolnih, zato velja:

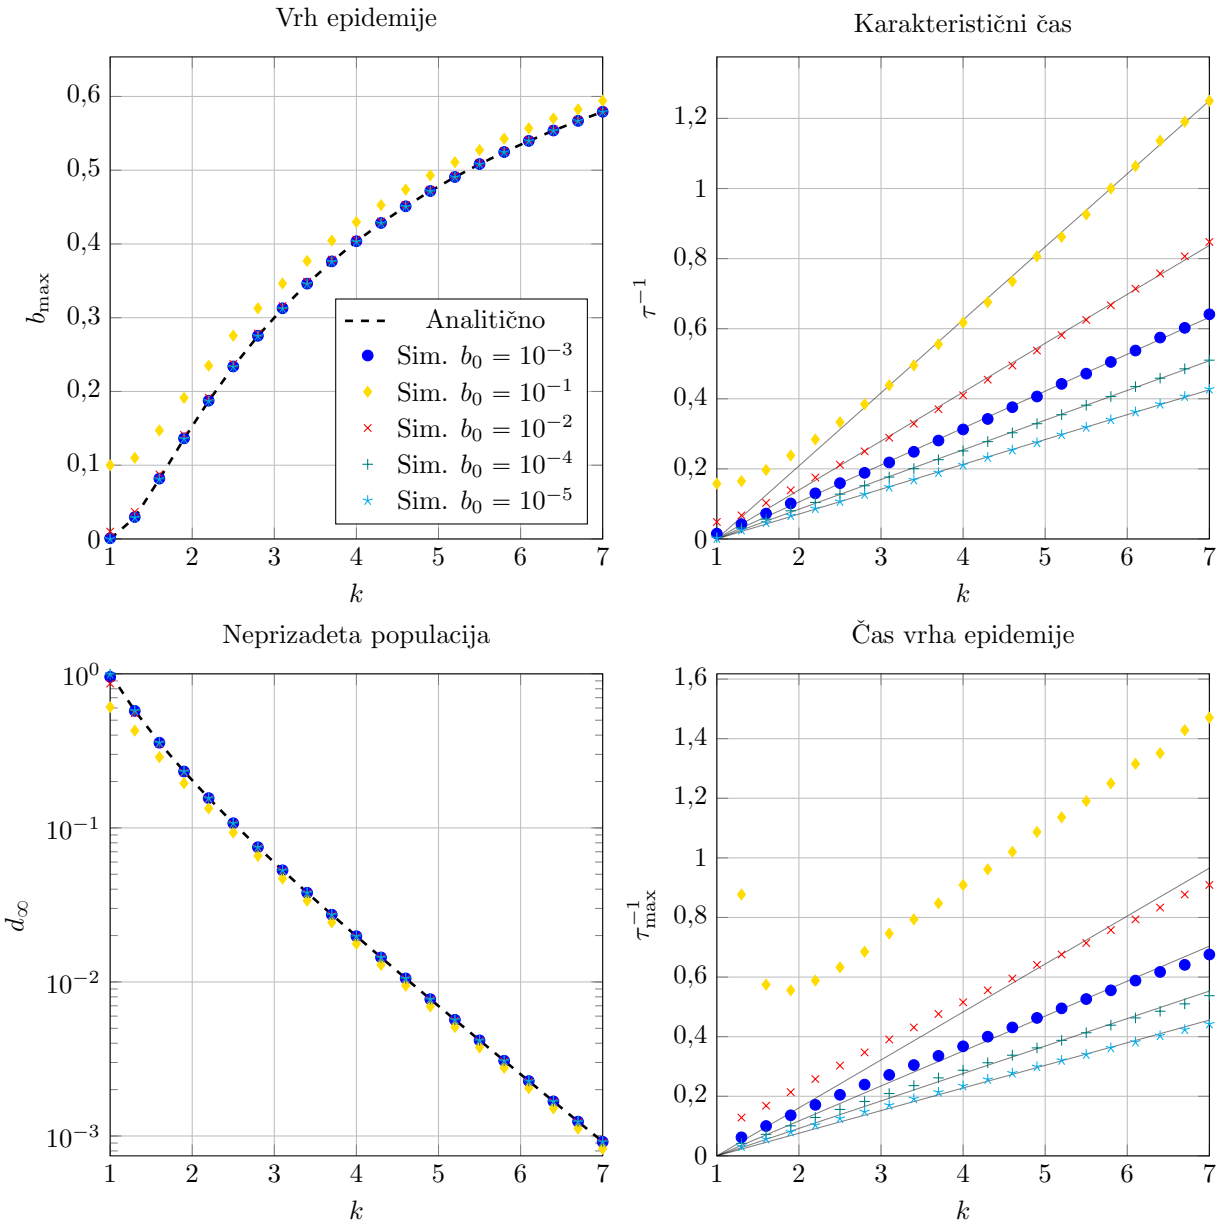
$$d_\infty = d_0 e^{-k(b_0+d_0-d_\infty)}, \tag{9}$$

oziroma s približkom $b_0 \ll 1$ in $d_0 \approx 1$:

$$d_\infty \approx e^{-k(1-d_\infty)}, \tag{10}$$

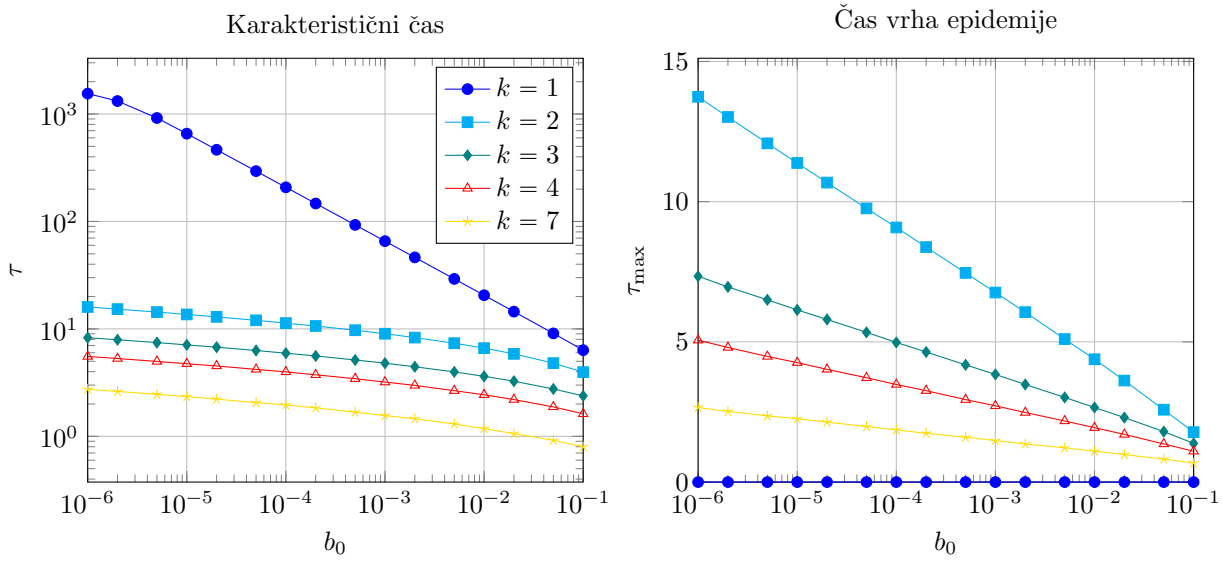
kar lahko rešimo numerično. Določimo še prej omenjeno največje število bolnih (vrh epidemije):

$$b_{\max} \approx 1 - \frac{1}{k}\left(1 + \ln(k)\right) \tag{11}$$



Graf 3: Odvisnost vrha epidemije, neprizadete populacije in karakterističnih časov od parametra k za nekaj različnih začetnih deležev obolelih. Pri večjih deležih obolelih pride do odstopanj od poenostavljenege modela.

Odstopanja od poenostavljenega modela so pričakovana, saj smo enačbo (8) poenostavili z začetnimi pogoji, ki za večje začetne deleže obolelih niso več tako upoštevani.



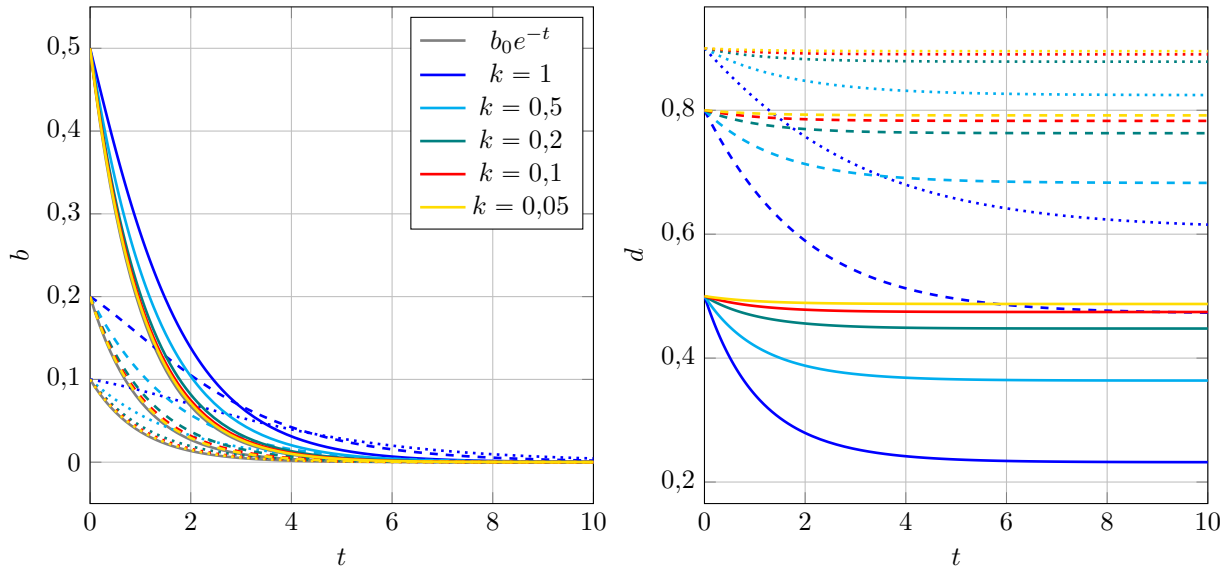
Graf 4: Odvisnost karakterističnega časa in časa vrha epidemije od začetnega deleža bolnih za nekaj vrednosti k.

V približku začetne eksponentne rasti lahko kot že omenjeno upoštevamo spremembo začetnega deleža obolelih kot premik v času za neko drugo epidemijo, saj velja

$$\tau \sim \frac{1}{k-1} \ln\left(\frac{b}{b_0}\right), \tag{12}$$

kar je seveda odvisno tudi od naše definicije karakterističnega časa. Za čas vrha v to enačbo vstavimo $b_{\max}$, ki pa je močno odvisen tudi od začetnega deleža obolelih in izkaže se, da dobimo približno eksponentno odvisnost, kar pa je seveda zopet približek. Poseben primer je $k = 1$, kjer je epidemija že ob začetnem času v vrhu in nato število obolelih le približno eksponentno pada (približek je odvisen od tega, koliko je še dovzetnih).

Za kompletnost si oglejmo še podkritične populacije $k \leqslant 1$.



Graf 5: Primeri za podkritične populacije. Za referenco narištemo tudi le eksponento pomjemanje ($k = 0$), ki res pade nekoliko hitreje, saj bolni le ozdravijo, nikogar pa ne okužijo na novo.

Tudi v tem primeru lahko analitično določimo izraz za končno število neprizadetih (ki pa ga rešimo numerično):

$$d_\infty = b_0 + d_0 + \frac{1}{k} \ln\left(\frac{d_\infty}{d_0}\right). \tag{13}$$

1.2 Cepljenje

Predpostavimo, da obstaja cepivo, ki je popolnoma učinkovito in zdrave osebke takoj naredi imune. Imamo več možnosti, kako karakterizirati cepljenje: konstantno ni najbolj realistično, bolj smiselno je uporabiti eno od možnosti, ki je odvisna od dogajanja – več kot je bolnih, bolj se ljudje bojijo in zato se jih več cepi, prav tako moramo upoštevati delež še neimunih (tj. dovzetnih, ker bolni bodo postali imuni), ta faktor nam tudi prepreči negativno število dovzetnih, do katerega bi lahko prišli v sunkoviti epidemiji, če bi upoštevali le strah zaradi osega bolezni. Ena od možnosti je naslednja:

$$\dot{d} = -kdb - cdb \tag{14}$$

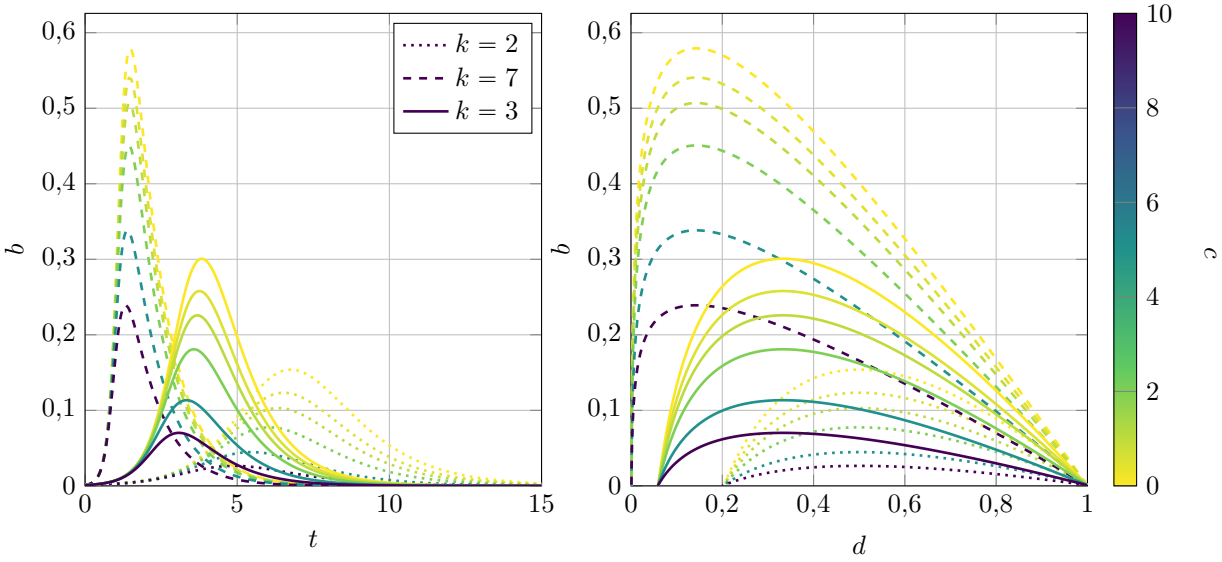
$$\dot{b} = kdb - b \tag{15}$$

$$\dot{i} = b + cdb \tag{16}$$

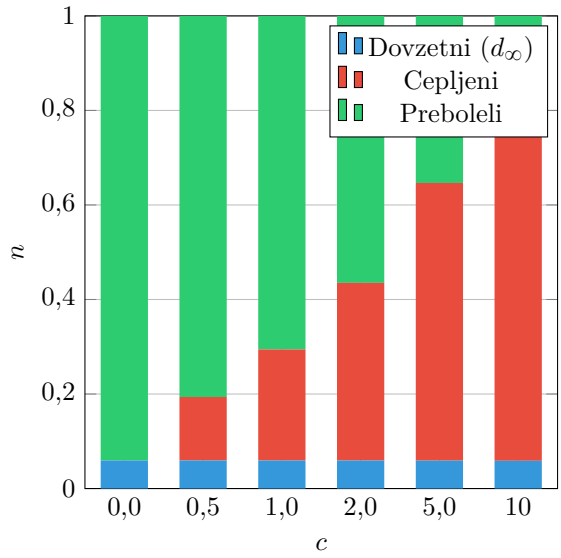
Stacionarno stanje je zopet populacija brez obolelih, Jacobian:

$$\begin{bmatrix} -(k+c)b & -(k+c)d & 0 \\ kb & kd-1 & 0 \\ cb & 1+cd & 0 \end{bmatrix} \quad \rightarrow \quad \begin{bmatrix} 0 & -(k+c)d & 0 \\ 0 & kd-1 & 0 \\ 0 & 1+cd & 0 \end{bmatrix} \tag{17}$$

Ker se cepljenje začne skupaj z epidemijo, ne spremeni pogoja za izbruh, le zniža vrh. Po drugi strani pa če je del populacije že imun v začetku, bo začetno število dovzetnih manjše, kar bo zmanjšalo možnost izbruha. Ta primer lahko obravnavamo popolnoma enako, kot primer brez začetne imunosti, saj lahko obravnavamo le del populacije brez začetnih imunih (pri tem moramo seveda paziti na renormalizacijo brezdimenzijskih spremenljivk in parametrov, se pa k in d skalirata enako, zato to ne vpliva na pogoj za izbruh), časovni potek bo identičen, zato si bomo ogledali le nekaj primerov za različne hitrosti cepljenja pri nadkritičnih populacijah, kjer je moč opaziti kaj zanimivega.



Graf 6: Vpliv parametra hitrosti cepljenja c za različne vrednosti k in začetni delež bolnih $b_0 = 10^{-3}$. Primer $c = 0$ je ekvivalenten osnovnemu modelu brez cepljenja.



Graf 7: Končna sestava populacije po epidemiji za različne hitrosti cepljenja c pri $k = 3$ in začetni delež bolnih $b_0 = 10^{-3}$.

Opazimo, da cepljenje zmanjša vrh epidemije in delež populacije, ki preboli bolezen, hkrati pa poveča delež imunih po epidemiji. Zanimivo, število dovzetnih po epidemiji ni odvisno od tega, kolikšen del populacije po tem modelu cepimo – za fazni diagram namreč lahko tudi za $k \to k + c$:

$$\frac{\dot{b}}{\dot{d}} = \frac{(1 - kd)b}{(k + c)db} \quad \to \quad \frac{k(1 - d_\infty)}{\cancel{k + c}} + \frac{\ln(d_\infty)}{\cancel{k + c}} = 0, \tag{18}$$

kar je res enak izraz, kot v primeru brez cepljenja. Tudi v tem primeru velja enaka omejitev, saj gre za približek, ko je $b_0 \ll 1$ in $d_0 \approx 1$.

1.3 Stadiji bolezni

Potek bolezni lahko razdelimo na tri stadije: inkubacijsko dobo (b_1), ko je osebek okužen, a še ne čuti simptomov in bolezni ne širi, sledi doba kužnosti (b_2), nato pa še doba okrevanja (b_3), ko osebek še ni zdrav, a tudi ne širi bolezni (izolacija).

$$\dot{d} = -kdb_2 \tag{19}$$
$$\dot{b_1} = kdb_2 - f_1 b_1 \tag{20}$$
$$\dot{b_2} = f_1 b_1 - b_2 \tag{21}$$
$$\dot{b_3} = b_2 - f_2 b_3 \tag{22}$$
$$\dot{i} = f_2 b_3 \tag{23}$$

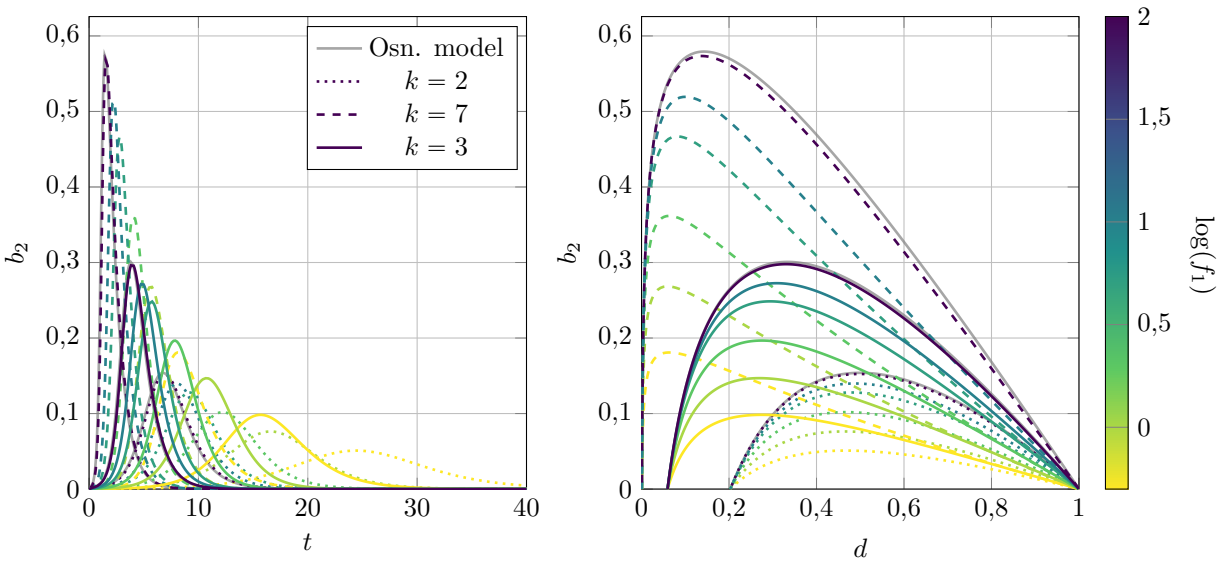
Preden se lotimo numerične analize, si oglejmo parametre problema: k enako kot prej opisuje, kako prenosljiva je bolezen, tokrat v primerjavi z dolžino kužne dobe, ki je najbolj naravna časovna skala za naš problem. Parameter f_1 opisuje, kako hitro osebek preide iz inkubacijske dobe v kužno, f_2 pa, kako hitro se v izolaciji osebek pozdravi in ni relevanten za naš problem, saj skrbi le za prehajanje iz b_3 v i, ki pa sama v modelu nimata nobenega vpliva na širjenje bolezni. Zopet za stacionarno stanje ne smemo imeti nobenih obolelih, Jacobian:

$$\begin{bmatrix} -kb_2 & 0 & -kd & 0 & 0 \\ kb_2 & -f_1 & kd & 0 & 0 \\ 0 & f_1 & -1 & 0 & 0 \\ 0 & 0 & 1 & -f_2 & 0 \\ 0 & 0 & 0 & f_2 & 0 \end{bmatrix} \quad \to \quad \begin{bmatrix} 0 & 0 & -kd & 0 & 0 \\ 0 & -f_1 & kd & 0 & 0 \\ 0 & f_1 & -1 & 0 & 0 \\ 0 & 0 & 1 & -f_2 & 0 \\ 0 & 0 & 0 & f_2 & 0 \end{bmatrix} \tag{24}$$

Od lastnih vrednosti sta dve 0, ena je enaka f_2 (praznenje izolacije: $b_3 \to i$), potem pa sta še zanimivejši dve:

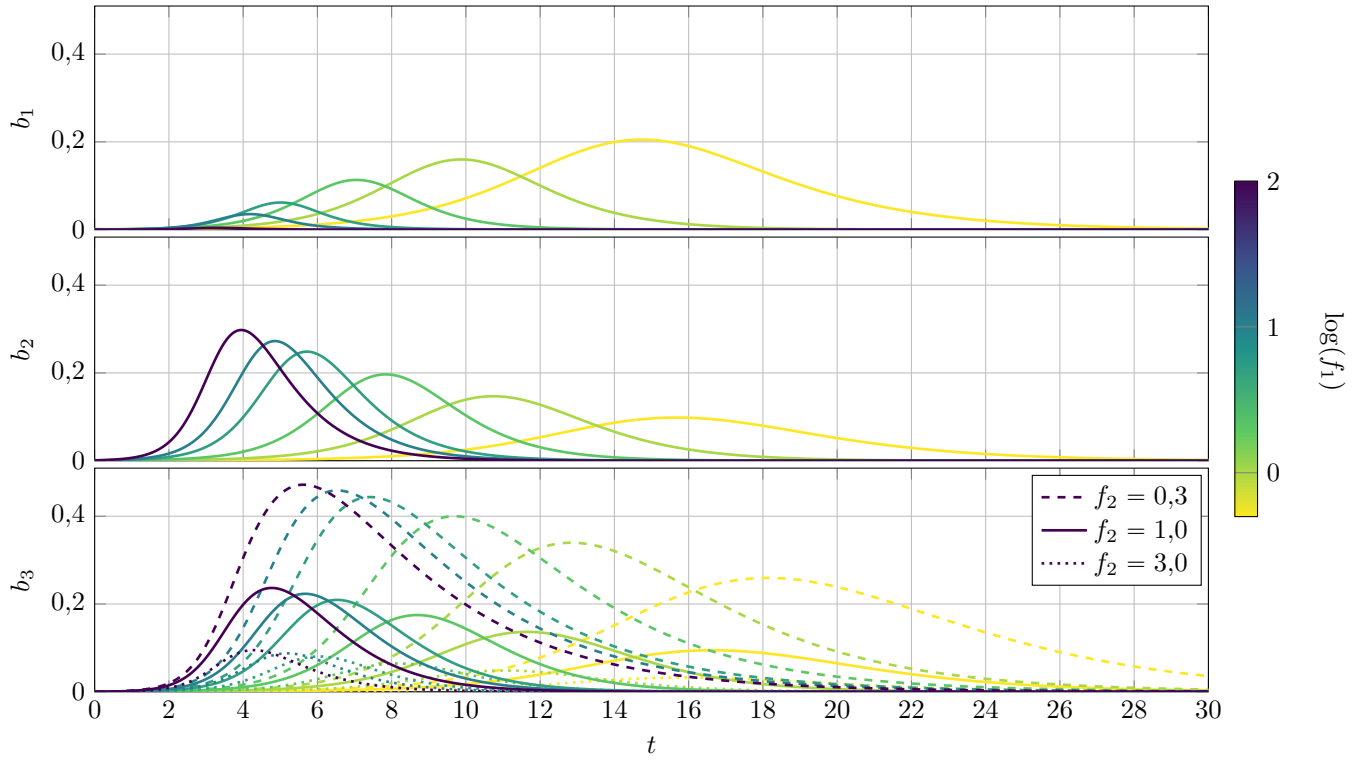
$$\frac{-1 - f_1 \pm \sqrt{1 - 2f_1 + 4dkf_1 + f_1^2}}{2}. \tag{25}$$

Rešitev s plusom je pozitivna pod pogojem $k > 1$ (za $d = 1$ ta izraz postane točno 0) in je tako pogoj za izbruh epidemije (začetna rast), ki je enak kot v osnovnem modelu.



Graf 8: Časovna odvisnost deleža kužne populacije (b_2) in fazni portreti za različne vrednosti parametra f_1 in nekaj vrednosti k. Za primerjavo so narisane tudi rešitve iz osnovnega modela ($f_1 \to \infty$). Začetni delež obolelih $b_1(0) = 10^{-3}$, $b_2(0) = b_3(0) = 0$.

Z grafa razberemo, da še vedno hitrost epidemije narekuje parameter k, vendar nanjo znatno vpliva tudi parameter f_1, ki določa, koliko časa osebek preživi v inkubacijski dobi – večji, kot je ta parameter, krajša je inkubacijska doba in bolj je potek podoben osnovnemu modelu, kjer inkubacijske dobe sploh ni. Daljša inkubacijska doba pomeni počasnejšo epidemijo, a ne zmanjša celotnega deleža populacije, ki preboli bolezen – zahvaljujoč naši izbiri brezdimenzijskih količin oz. parametrov se doba kužnosti namreč ujema s trajanjem bolezni v osnovnem modelu, zato edino k določa, koliko ljudi bo zbolelo (dokler je začetno število bolnih majhno).



Graf 9: Časovne odvisnosti po stadijih za različne vrednosti parametra f_1 in $k = 3$. Narisane so tudi rešitve za tretji stadij (b_3) za različne vrednosti f_2. Začetni delež obolelih $b_1(0) = 10^{-3}$, $b_2(0) = b_3(0) = 0$.

Kot opisano, f_2 ne vpliva na širjenje bolezni, ampak le na tretji stadij – če je f_2 majhen (dolgotrajno okrevanje), se med vrhom epidemije v tem stadiju nakopiči več bolnih, medtem ko do tolikšnega kopičenja ne pride, če je f_2 velik (hitro okrevanje). V vsakem primeru pa vrh epidemije v tretjem stadiju nastopi za vrhom v prvih dveh stadijih (kavzalnost).

1.4 Kombiniran model

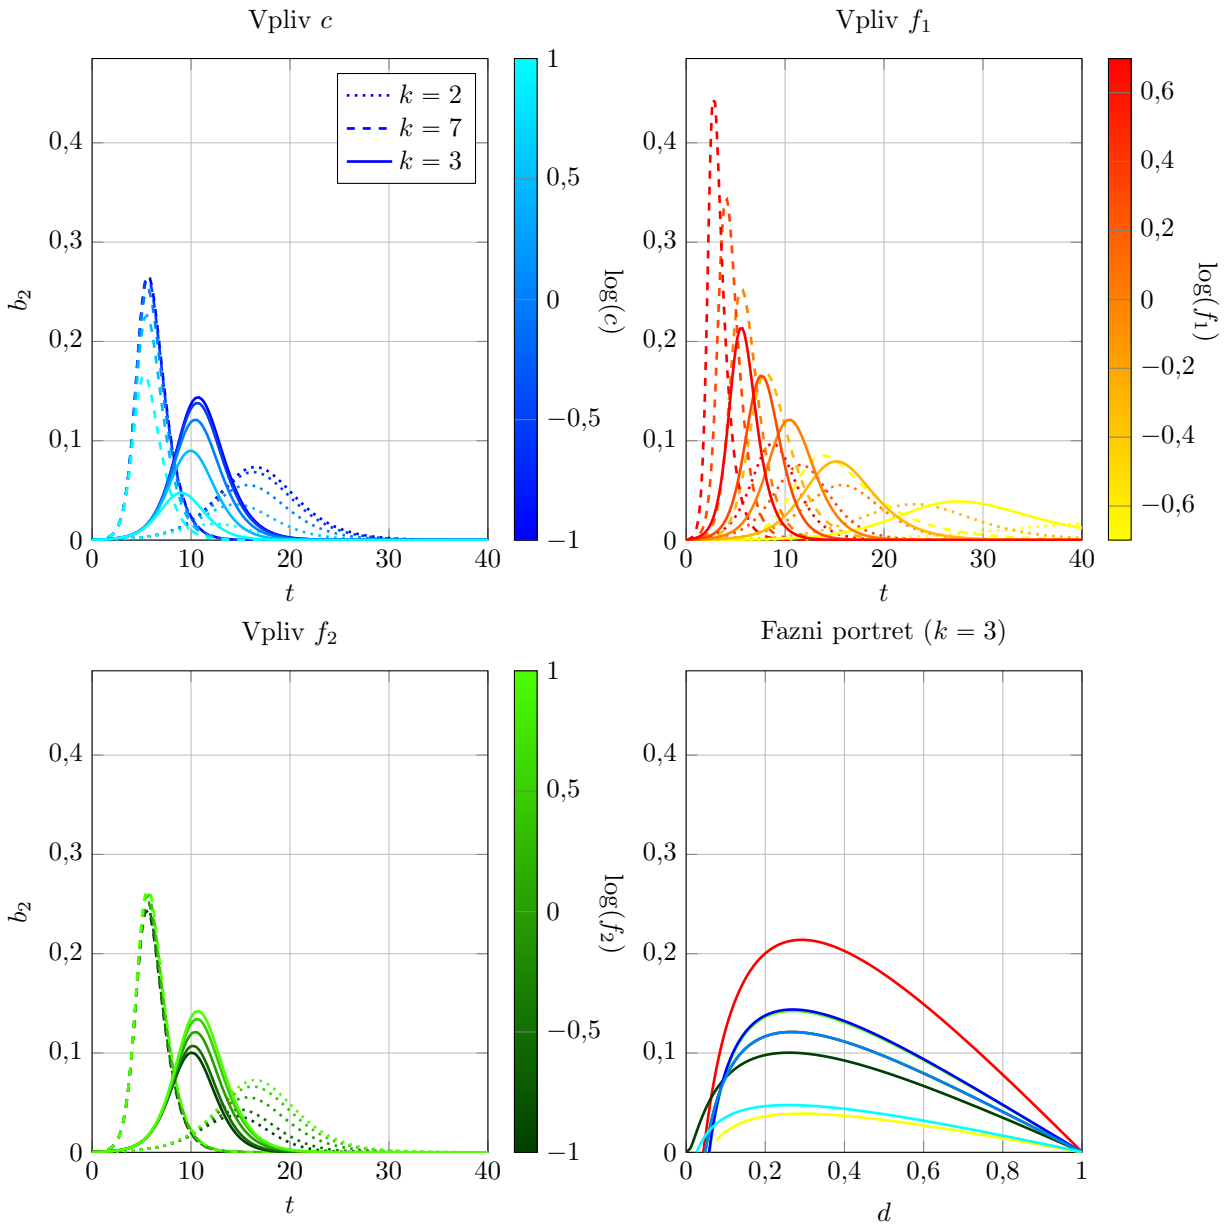
Če združimo tako možnost cepljenja kot tri stadije in upoštevamo še realnost, da cepivo ne deluje takoj, ampak kot se je izkazalo v zadnjih letih povzroča kratkotrajno še višjo dovzetnost (prvo, imunski sistem takoj po cepljenju zaradi sprejemanja začasno oslabi; drugo, ljudje se že takoj po cepljenju počutijo varne in so zato manj previdni pri preventivi) – χ:

$$\dot{d} = -kdb_2 - cdb_3 \tag{26}$$
$$\dot{v} = cdb_3 - \varepsilon v - \chi v b_2 \tag{27}$$
$$\dot{b_1} = kdb_2 - f_1 b_1 + \chi v b_2 \tag{28}$$
$$\dot{b_2} = f_1 b_1 - b_2 \tag{29}$$
$$\dot{b_3} = b_2 - f_2 b_3 \tag{30}$$
$$\dot{i} = f_2 b_3 + \varepsilon v \tag{31}$$

Tudi v tem modelu je stacionarno stanje populacija brez obolelih, dodaten pogoj pa je tudi, da vsi cepljeni prestanejo prvo fazo in postanejo imuni, Jacobian:

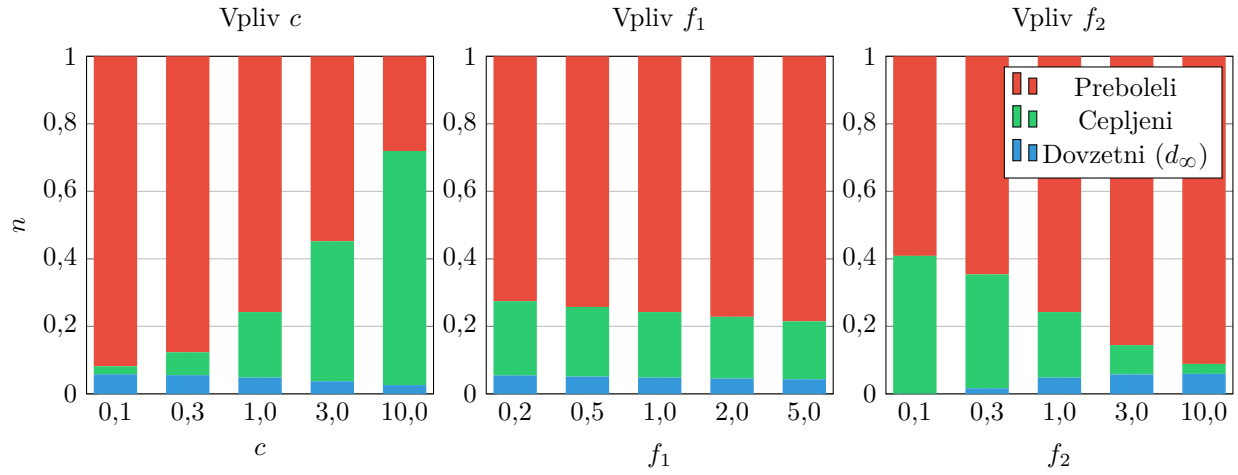
$$\begin{bmatrix} -kb_2 - cb_3 & 0 & 0 & -kd & -cd & 0 \\ cb_3 & -\varepsilon - \chi b_2 & 0 & -\chi v & cd & 0 \\ kb_2 & \chi b_2 & -f_1 & kd + \chi v & 0 & 0 \\ 0 & 0 & f_1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -f_2 & 0 \\ 0 & \varepsilon & 0 & 0 & f_2 & 0 \end{bmatrix} \rightarrow \begin{bmatrix} 0 & 0 & 0 & -kd & -cd & 0 \\ 0 & -\varepsilon & 0 & 0 & cd & 0 \\ 0 & 0 & -f_1 & kd & 0 & 0 \\ 0 & 0 & f_1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -f_2 & 0 \\ 0 & \varepsilon & 0 & 0 & f_2 & 0 \end{bmatrix} \tag{32}$$

Lastne vrednosti v začetnem stanju so enake, kot v prejšnjem primeru, pridobimo le še eno novo: $-\varepsilon$. Analiza je zaradi velikega števila parametrov precej bolj zapletena, zato se je moramo lotiti sistematično, tako da gledamo vplive posameznih parametrov na potek. Začeli bomo z idealnim cepivom, ki ne poveča dovzetnosti ($\chi = 0$, v tem primeru je vrednost ε nepomembna, saj niti v niti i ne vplivata na širjenje). To je direktna kombinacija obeh zgornjih nadgradenj. Pomembni parametri so k, c, f_1 in zaradi hitrosti cepljenja tudi f_2 – daljše, kot je okrevanje (manjši f_2), več bolnih se bo nakopičilo v tretjem stadiju, kar bo privedlo do večjega povpraševanja po cepljenju.



Graf 10: Vpliv novih parametrov na potek epidemije z idealnim cepivom. Spreminjamo po en parameter naenkrat, ostali so na privzetih vrednostih: $k = 3$, $c = 1, f_1 = 1, f_2 = 1$. Začetni delež bolnih $b_1(0) = 10^{-3}$, $b_2(0) = b_3(0) = v(0) = i(0) = 0$.

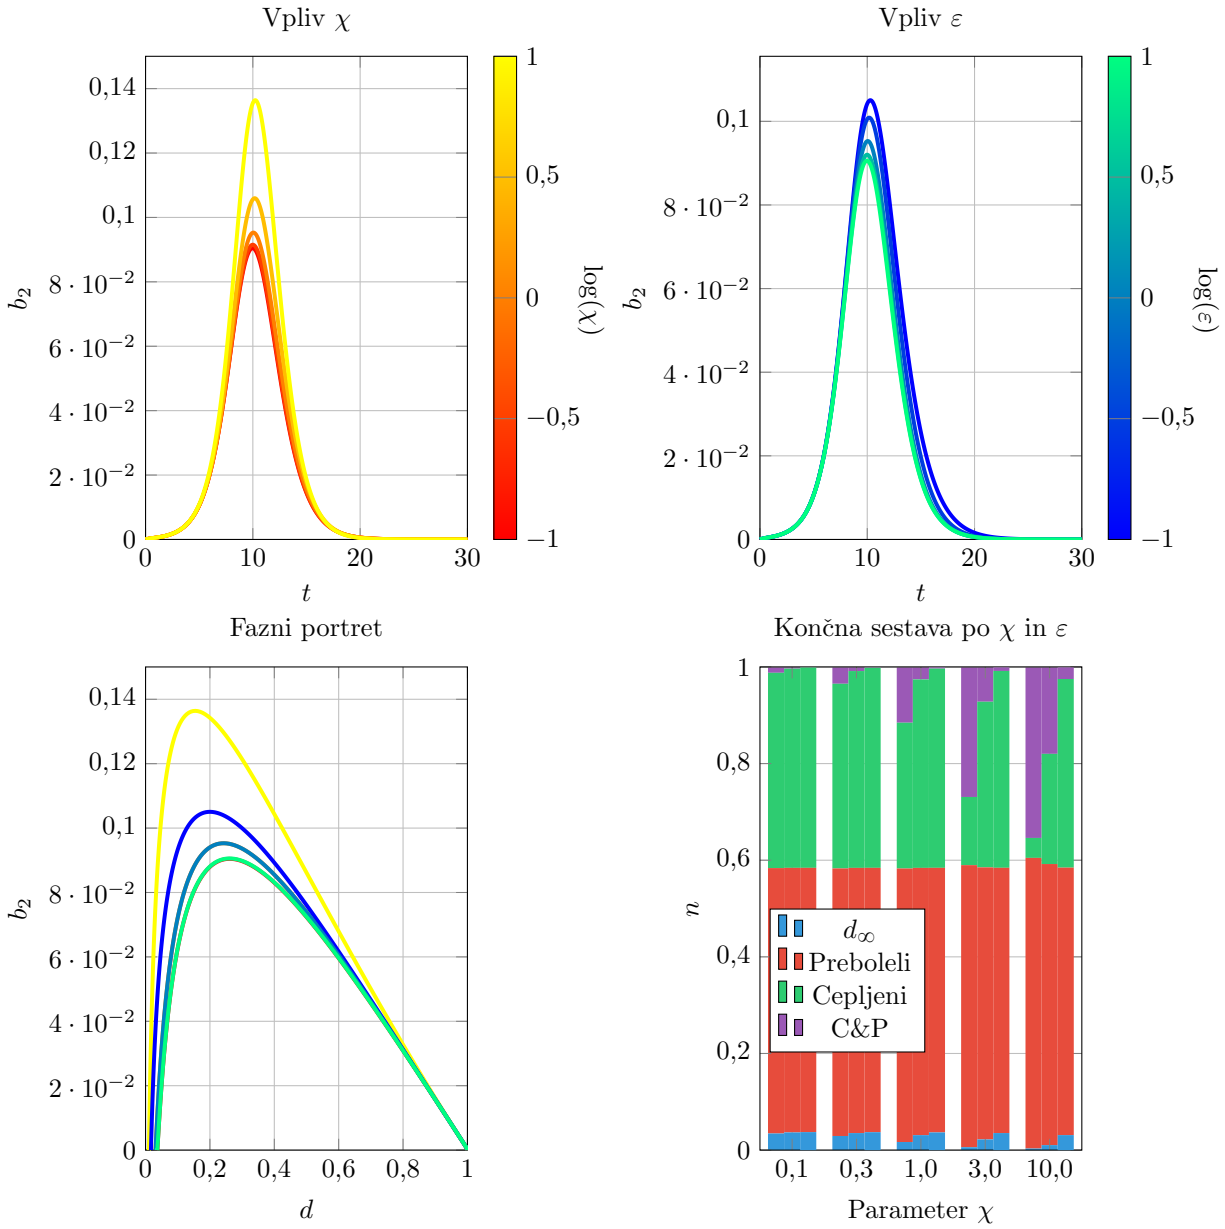
Hitrejše cepljenje zmanjša vrh epidemije in ga tudi časovno približa začetku (podobno kot pri modelu brez stadijev). Krajša inkubacijska doba ima nasproten učinek – višji vrh, ki pride prej. V našem modelu ima vpliv tudi dolžina okrevanja v tretjem stadiju – daljše okrevanje pomeni več bolnih v tretjem stadiju, kar poveča povpraševanje po cepljenju in je efektivno podobno kot hitrejše cepljenje.



Graf 11: Končna sestava populacije po epidemiji z idealnim cepivom. Spreminjamo po en parameter naenkrat, ostali so na privzetih vrednostih: $k = 3$, $c = 1, f_1 = 1, f_2 = 1$. Začetni delež bolnih $b_1(0) = 10^{-3}$, $b_2(0) = b_3(0) = v(0) = i(0) = 0$.

Posebej velja omeniti vpliv hitrosti okrevanja (v tretjem stadiju), ki znatno vpliva na končno sestavo, saj se v tem stadiju nakočpiči več bolnih, kar ohranja povpraševanje po cepljenju, tudi ko je že manj dovzetnih, zato dovzetnih po epidemiji v primeru počasnejšega okrevanja ostane manj, več pa je cepljenih in manj prebolelih. V primeru hitrejšega okrevanja pa skoraj nimamo bolnih v tretjem stadiju, zato je malo povpraševanja po cepljenju.

Sedaj dopustimo še možnost povečane dovzetnosti kratek čas po cepljenju, ki nam odpre še parametra χ in ε.



Graf 12: Vpliv neidealnosti cepiva (večja dovzetnost v kratkem obdobju po cepljenju) na potek epidemije. Spreminjamo po en parameter naenkrat, ostali so na privzetih vrednostih: $k = 3$, $c = 3, f_1 = 1, f_2 = 1, \chi = 1, \varepsilon = 1$. Začetni delež bolnih $b_1(0) = 10^{-3}$, $b_2(0) = b_3(0) = v(0) = i(0) = 0$. Na stolpičnem diagramu so stolpci končnih sestav grupirani po trije: levi je za $\varepsilon = 0{,}1$, srednji za $\varepsilon = 1$ in desni za $\varepsilon = 10$.

Kot pričakovano ima večja dovzetnost takoj po cepljenju (χ) negativen vpliv na potek epidemije, saj se po cepljenju okuži tudi del cepljenih. Krajša doba učinkovanja cepljenja (ε) pa ima nasproten efekt, saj je verjetnost okužbe po cepljenju manjša. Kombinacija visoke dovzetnosti in počasnega delovanja privede do tega, da je znaten delež populacije po cepljenju tudi bolan.

1.5 Model z zakasnitvijo

Če se vrnemo k modelu s tremi stadiji. ga lahko rešujemo tudi z zakasnitvijo. V tem primeru ne potrebujemo prve faze, saj naraščanje v drugem stadiju opišemo že iz zgodovine dovzetnih in kužnih.

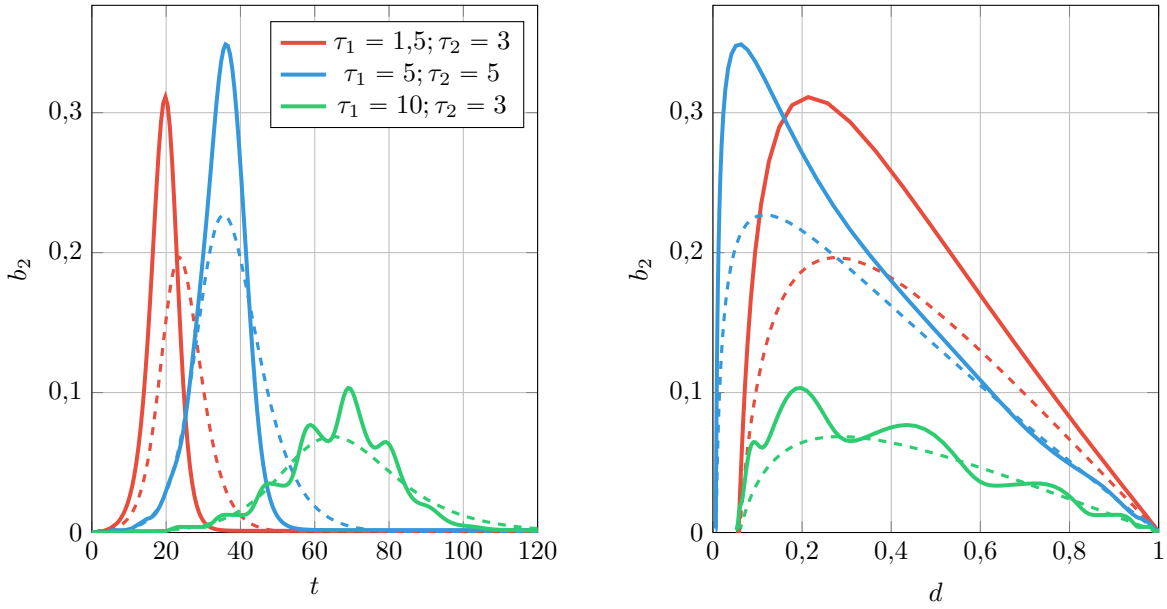
$$d \xrightarrow{k} b_1 \xrightarrow{\tau_1} b_2 \xrightarrow{\tau_2} b_3 \to i$$

To v praksi pomeni, da želimo obolevanje opisati s kužnimi pred τ_1:

$$\dot{d} = -kd(t)b_2(t) \tag{33}$$

$$\dot{b_2} = kd(t-\tau_1)b_2(t-\tau_1) - kd(t-\tau_1-\tau_2)b_2(t-\tau_1-\tau_2) \tag{34}$$

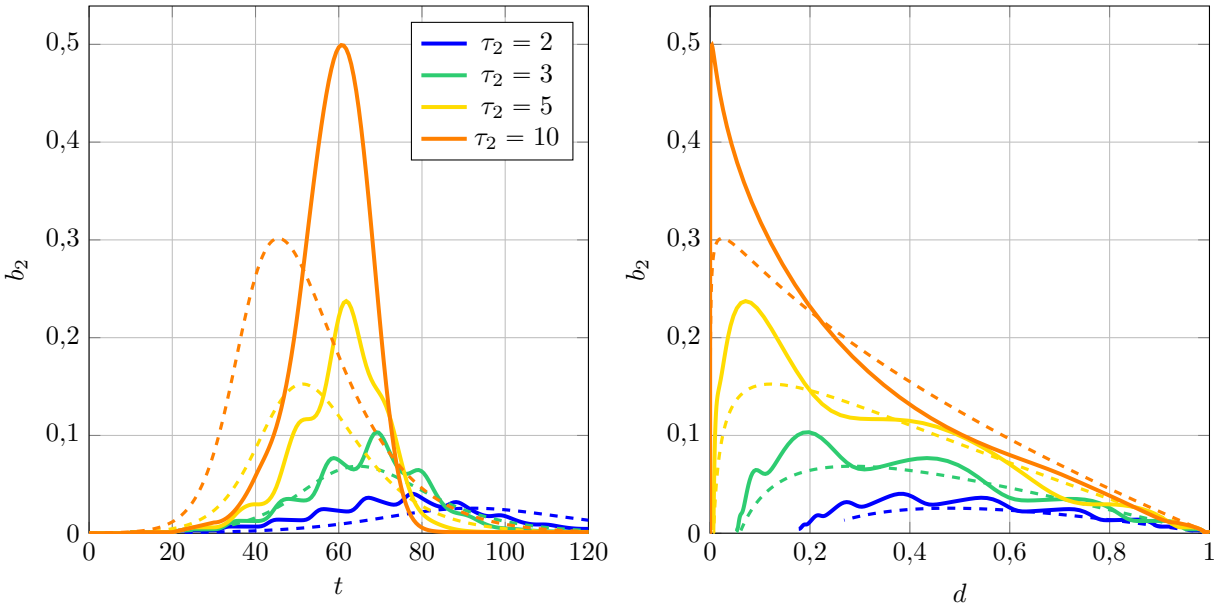
V tem primeru nam število bolnih v tretjem stadiju (b_3) in število imunih (i) ne vpliva na širjenje bolezni, zato se lahko enega od parametrov (npr. k) znebimo, kot f_2, ki ni imel vpliva na širjenje bolezni.



Graf 13: Primerjava modela z zakasnitvijo z modelom treh stadijev (prekinjenja črta) za enake parametre ($k = 3$, ostale parametre uskladimo s časi stadijev).

Opazimo nekaj razlik med modeloma, predvsem za dolge inkubacijske dobe (τ_1), kjer na začetku pride do stopničastih vzponov z ravno tem karakterističnim časom – okuženih je namreč malo, dovzetni pa so še praktično vsi, zato se na novo okužujejo sorazmerno s številom bolnih, a z zakasnitvijo, ki je enaka dolžini inkubacijske dobe. V tem primeru je τ_2 nastavljen ravno tako, da izgledajo stopnice sprva ravne, vendar to v splošnem ne velja – za daljše τ_2, ko bo okrevanje iz kužne dobe počasnejše, bo stopničast v resnici odvod b_2.

Velja omeniti, da je bila koda za zakasnjene diferencialne enačbe napisana ročno po navodilih s predavanj, zato ni nujno tako učinkovita kot `scipy.integrate.solve_ivp`, ki ima tudi adaptiven korak in verjetno teče nekoliko hitreje. Uporabljena je bila delitev na 12000 korakov (korak 0,01), vendar se ob spremembah števila korakov pojavijo še manjše spremebe – predvsem položaj vrha za najkrajšo inkubacijsko dobo se nekoliko premakne pri določenih izbirah korakov, se pa višina vrha in fazni diagram skoraj ne spremenita, zato gre očitno le za natančnost pri začetni rasti bolnih.



Graf 14: Primerjava modela z zakasnitvijo z modelom treh stadijev pri različnih τ_2 in $\tau_1 = 10$, ki v različni meri kažejo stopničasto obnašanje.

Pri vseh narisanih primerih opazimo stopničasto obnašanje (tudi pri $\tau_2 = 10$, kjer je izrazito stopničast odvod, kar je razvidno iz naklonov v začetku rasti), kar je kot opisano posledica različnih stopenj kopičenja bolnih v prvem stadiju, ki se nato sproščajo v kužno dobo (medtem ko je na začetku populacija dovzetnih še skoraj cela).

2 Zajci in lisice

Preprost model za populaciji zajcev in lisic: zajci se množijo eksponentno, lisice pa jih jedo (več kot je zajcev in več kot je lisic), da se lahko množijo, a naravno umirajo. To opisujeta enačbi:

$$\dot{Z} = \alpha Z - \beta Z L \tag{35}$$

$$\dot{L} = -\gamma L + \delta Z L \tag{36}$$

Brezdimenzijske spremenljivke: $t \to t\sqrt{\alpha/\gamma}$, $\eta = \alpha/\gamma$, ($l = \beta L/\alpha$, $z = \delta Z/\gamma$):

$$\dot{z} = \eta z(1 - l) \tag{37}$$

$$\dot{l} = \frac{l}{\eta}(z - 1) \tag{38}$$

Zopet lahko zelo hitro opazimo potencialna stacionarna stanja:

- $z = 0, l = 0$ – ni nobene populacije, trivialno stacionarno stanje, ker ni nobenih osebkov, se ne morejo množiti;
- $z = 1, l = 1$ – ravnovesna koeksistenca obeh populacij – vsakih je ravno toliko, da se populaciji ne spreminjata.

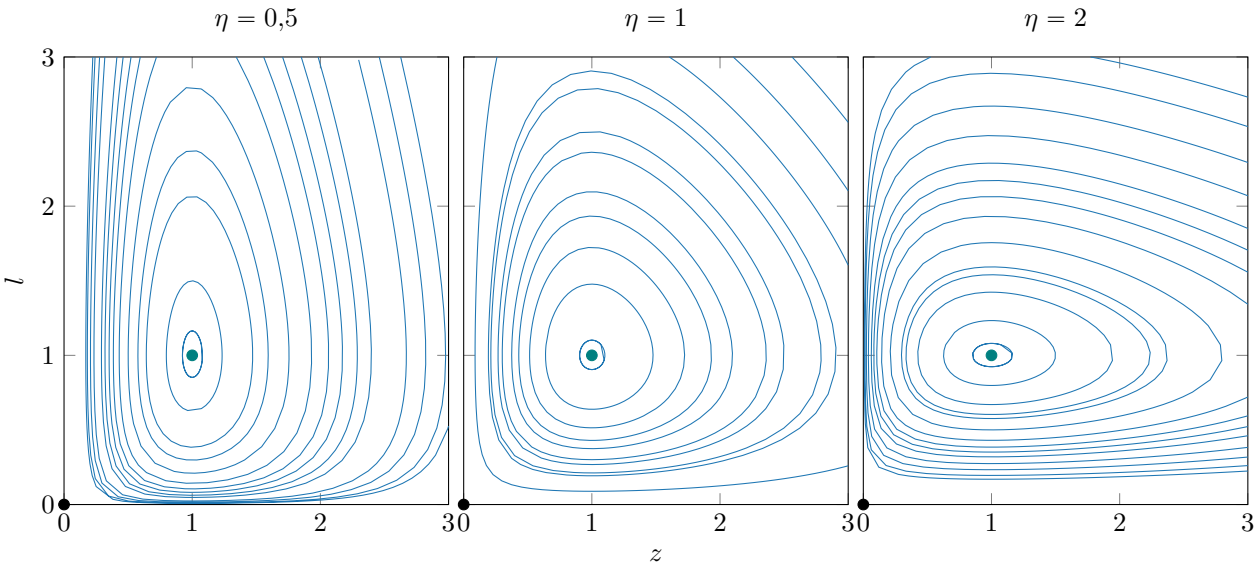
Jacobian je tokrat manjša matrika, ker imamo le dve populaciji:

$$\begin{bmatrix} \eta(1-l) & -\eta z \\ \frac{l}{\eta} & \frac{z-1}{\eta}, \end{bmatrix} \tag{39}$$

karakteristična polinoma za obe stacionarni stanji imata vsak po dve različni lastni vrednosti:

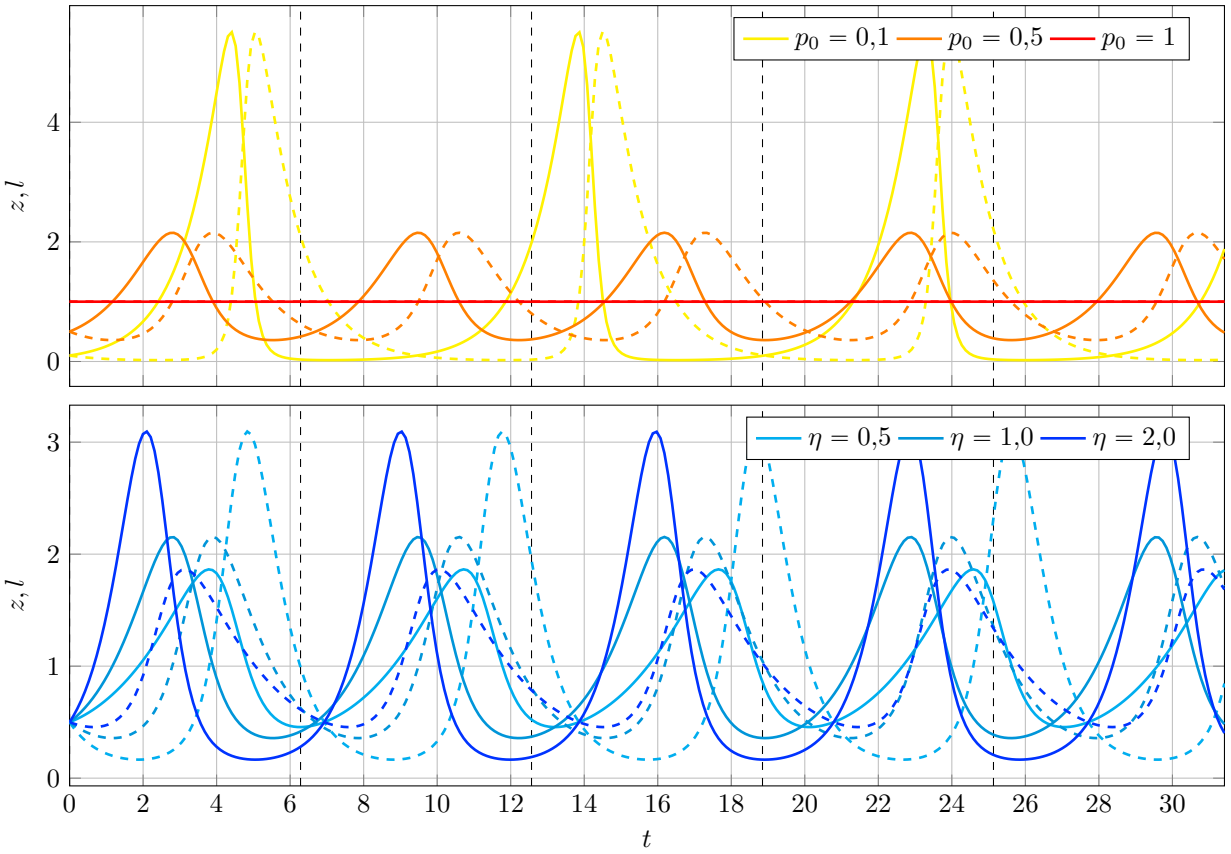
$$\lambda_1 = \pm\eta^{\pm 1}; \qquad \lambda_2 = \pm i. \tag{40}$$

Prvi primer opisuje širjenje populacije, če sta populaciji blizu 0. Ta točka je sedlo – če je malo zajcev in ni lisic, se bodo množili eksponentno, medtem ko bo malo lisic brez zajcev eksponentno izumrlo. Drugi primer opisuje koeksistenco in kotno hitrost nihanja okoli ravnovesne točke zanjo.



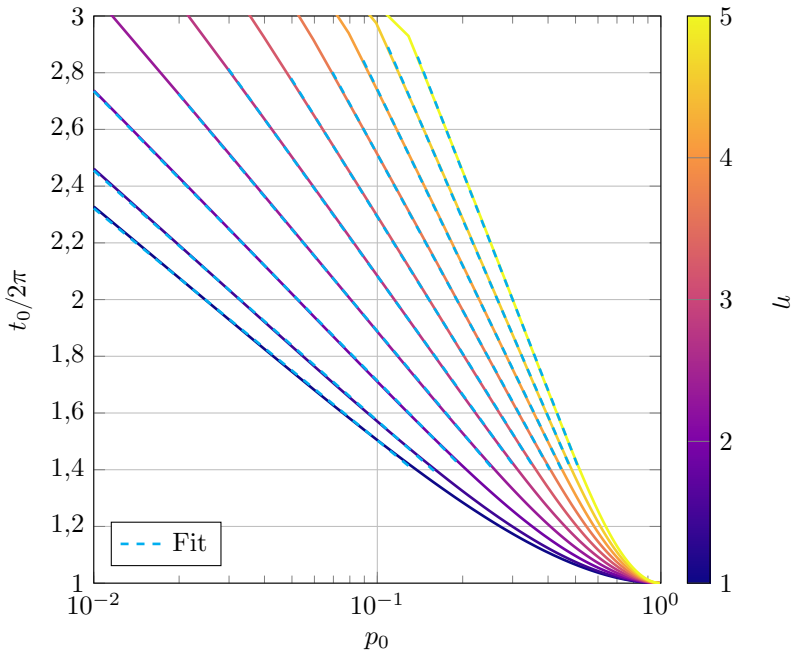
Graf 15: Fazni diagrami za različne vrednosti η. Stacionarna točka $(1, 1)$ je res neodvisna od parametra η.

Fazni diagrami nam povedo, da lahko pričakujemo periodično obnašanje, saj so črte zaključene same vase, kar pomeni, da se populaciji vedeta periodično. S tem tudi vemo, da lahko pridemo na poljubno (neničelno) stanje z začetnim pogojem enako velikih populacij nekje na intervalu $(0, 1]$ ali pa z eno od populacij velikosti 1 in drugo nekje na istem intervalu.



Graf 16: Časovna odvisnost populacij zajcev in lisic za različne začetne velikosti obeh populacij (p_0) in različne vrednosti η za $p_0 = 0{,}5$. Polna črta predstavlja zajce, prekinjena lisice. Z navpičnimi prekinjenimi črnimi črtami so označeni časi periode 2π.

Z grafov razberemo, da za začetne populacije ne predaleč od koeksistenčne velikosti perioda skoraj ustreza 2π, kakor to napovedujejo lastne vrednosti, parameter η pa pri izbranih vrednostih tudi nima velikega vpliva na periodo, je pa za vse vrednosti perioda daljša od 2π, torej ima bistveno vlogo velikost populacije.



Graf 17: Vpliv začetnih velikosti populacije (p_0) in parametra η na periodo oscilacij populacij zajcev in lisic. Rišemo le $\eta \geqslant 1$, saj so manjše vrednosti ekvivalentne obratnim obratnim vrednostim. Pri prevelikih oscilacijah (daljše periode, npr. $\eta = 5$ in manjša začetna populacija) pride do numeričnih težav, obnašanje ni več poplnoma periodično (ne vrne se popolnoma v začetno stanje). V delu med periodami 1,4 in 2,9 lahko prilegamo eksponentno (v skali linearno) funkcijo.

Fenomenološko opazimo, da bi lahko prilegali eksponentno funkcijo za dovolj majhne začetne populacije. Žal se nakloni v odvisnosti od začetne populacije ne ujemajo z nobeno enostavno funkcijo.

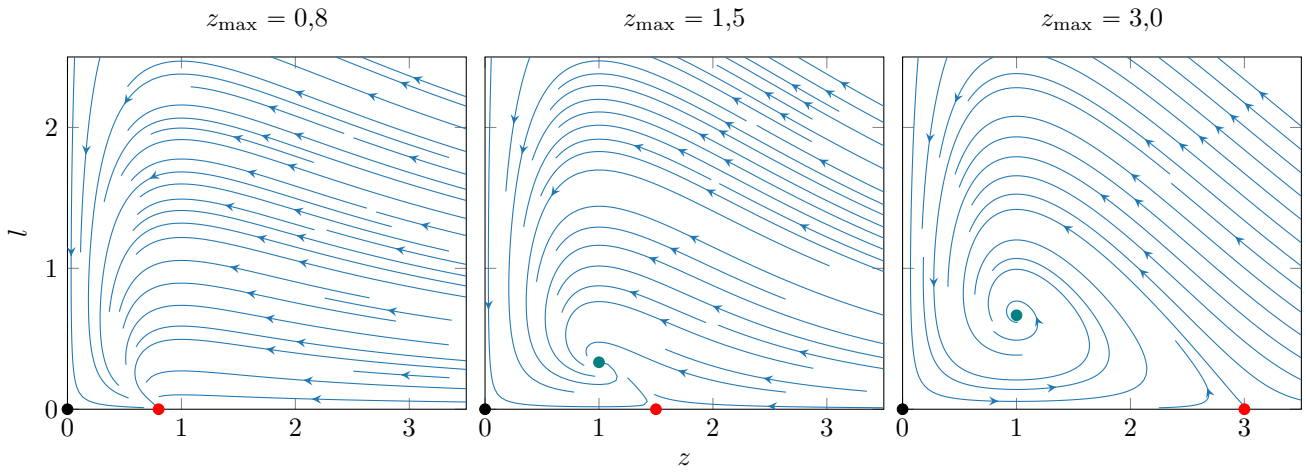
2.1 Nadgradnje modela

Opazimo, da se zajci ob pomanjkanju lisic zelo namnožijo, kar ni najbolj realistično. Da bi model izboljšali, lahko omejimo maksimalno število zajcev (logistično), ali pa dodamo člen prehranjevalne verige (npr. travo) pred zajce, ki ga lahko implementiramo podobno, kot smo implementirali odnos med zajci in lisicami (v tem primeru bo verjetno prišlo do oscilacij, tako kot pri modelu s samo zajci in lisicami), ali pa npr. logistično (da raste, dokler ne zapolni okolja, kar bi moralo nihanje populacij sčasoma zadušiti), kar je verjetno bolj realistično, sploh če predpostavimo, da zajec travo odgrizne in ne izruva, zato lažje raste naprej in ne potrebuje razmnoževanja. Travo bomo označevali z g. Enačbe za nadgrajenega modela izgledajo takole:

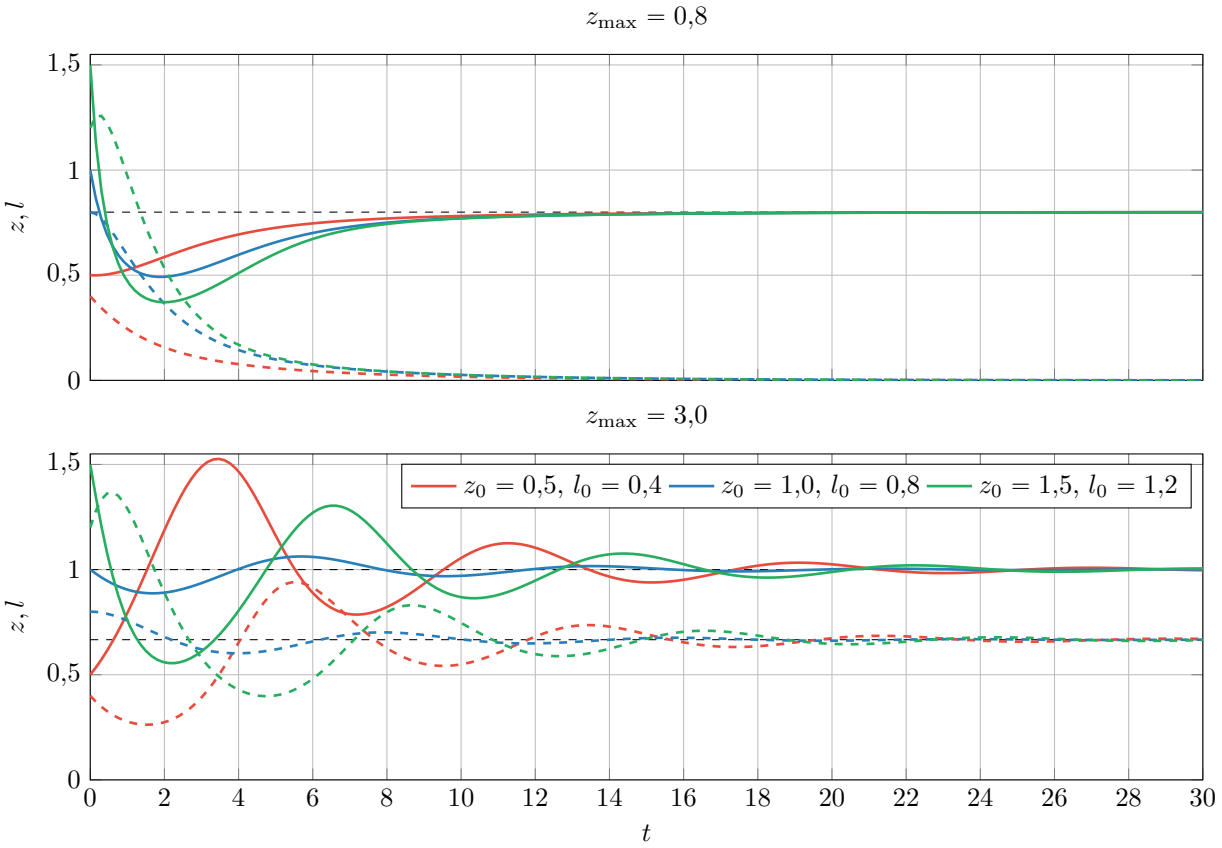
A) omejitev števila zajcev (logistično)

$$\dot{z} = \eta z \left(1 - \frac{z}{z_{\max}} - l\right) \tag{41}$$

V tem primeru se koeksistenčno stacionarno stanje spremeni: $l = 1, z = 1 - 1/z_{\max}$ (seveda delamo v brezdimenzijski obliki, zato to ne pomeni, da je lisic enako kot prej, zajcev pa manj), ki je stabilno, vendar obstaja le za $z_{\max} > 1$. Dobimo še dodatno stacionarno stanje brez lisic, ko so zajci na omejitvi ($z = z_{\max}$), ki pa je sedlo (zajci so stabilni, pojav lisic pa bo povzročil izhod iz točke) za $z_{\max} > 1$, sicer pa stabilna točka. Fazni portreti nam razkrijejo, da imamo v takem modelu le dva možna scenarija: prenizka omejitev zajcev vodi v izumrtje lisic, medtem ko višja omejitev vodi v koeksistenco populacij.



Graf 18: Fazni portreti za različne vrednosti $z_{\max}$ in $\eta = 1$.



Graf 19: Nekaj primerov začetnih pogojev za $z_{\max} \in \{0{,}8; 3{,}0\}$ in $\eta = 1$.

B) trava z eksponentno rastjo

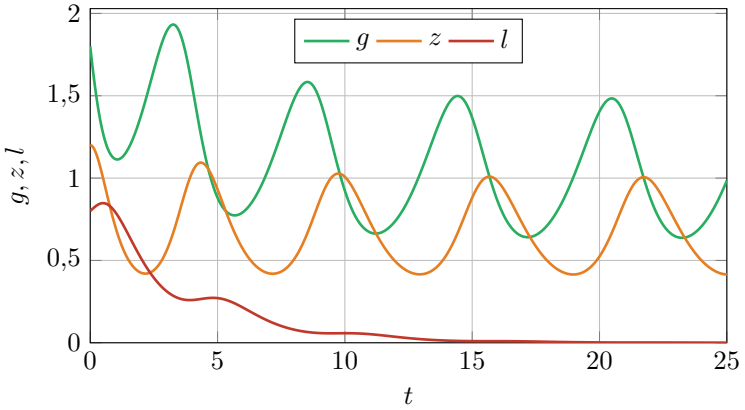
$$\dot{g} = g(1 - \chi z) \tag{42}$$
$$\dot{z} = \eta z(g - l - 1) \tag{43}$$

Parameter χ opisuje vpliv zajcev na travo. Trivialno stacionarno stanje je brez populacij: če se v tem primeru pojavi malo trave, bo rastla eksponentno; če se pojavijo zajci ali lisice, izumrejo; če se pojavi trava in zajci, bo to enako, kot zajci in lisice v osnovnem modelu; če se pojavijo lisice in zajci, populaciji izumreta. Poleg koeksistence trave

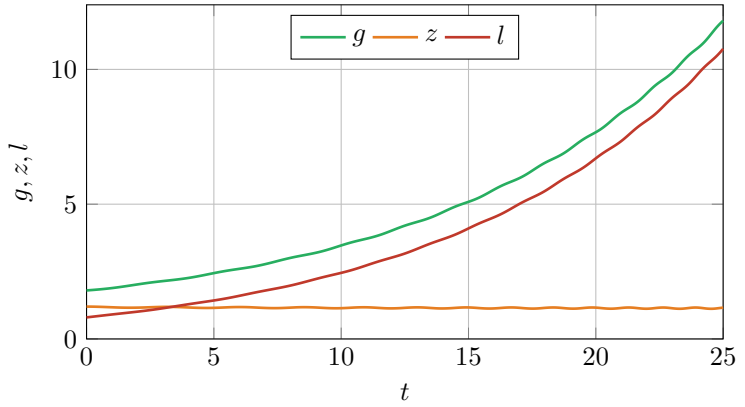
in zajcev (kot v osnovnem modelu) se pojavi še koeksistenca vseh treh populacij: če je $\chi = 1$, lahko stabiliziramo $z = 1, g > 1, l = g - z = g - 1$. V tem primeru dobimo neničelni lastni vrednosti

$$\lambda = \pm\sqrt{g_{\text{stac}}\,(1+\eta) - 1}, \tag{44}$$

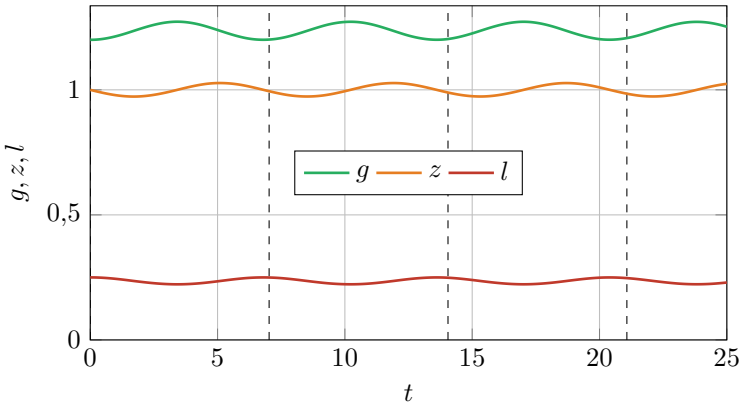
kar je za preveliko η nestabilno, sicer pa nihajoče (kompleksne lastne vrednosti).



Graf 20: Primer nestabilne rešitve, kjer lisice izumrejo ($\chi = 1, \eta = 1$).



Graf 21: Primer nestabilne rešitve, kjer lisice in trava rastejo, zajčja populacija pa se ne spreminja ($\chi = 0{,}8, \eta = 1{,}5$). Zajci se v tem primeru množijo vse hitreje (več trave), a jih lisice (ker jih je vedno več) tudi vedno hitreje jedo, zato je njihova populacija konstantna, medtem ko preostali dve naraščata.



Graf 22: Primer stabilne rešitve za sistem s travo ($\chi = 1, \eta = 0{,}5$) z rahlo preveliko začetno populacijo lisic. Prekinjene navpične črne označujejo periode.

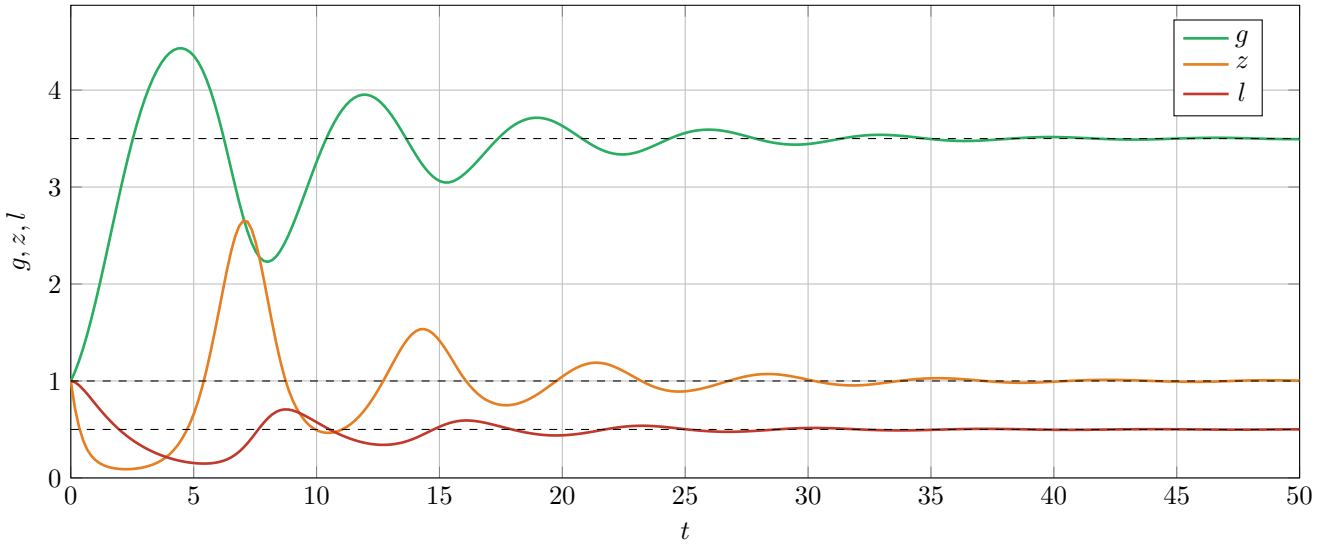
C) trava z logistično rastjo

Obdržimo prvotno definicijo parametra η in dodamo travo

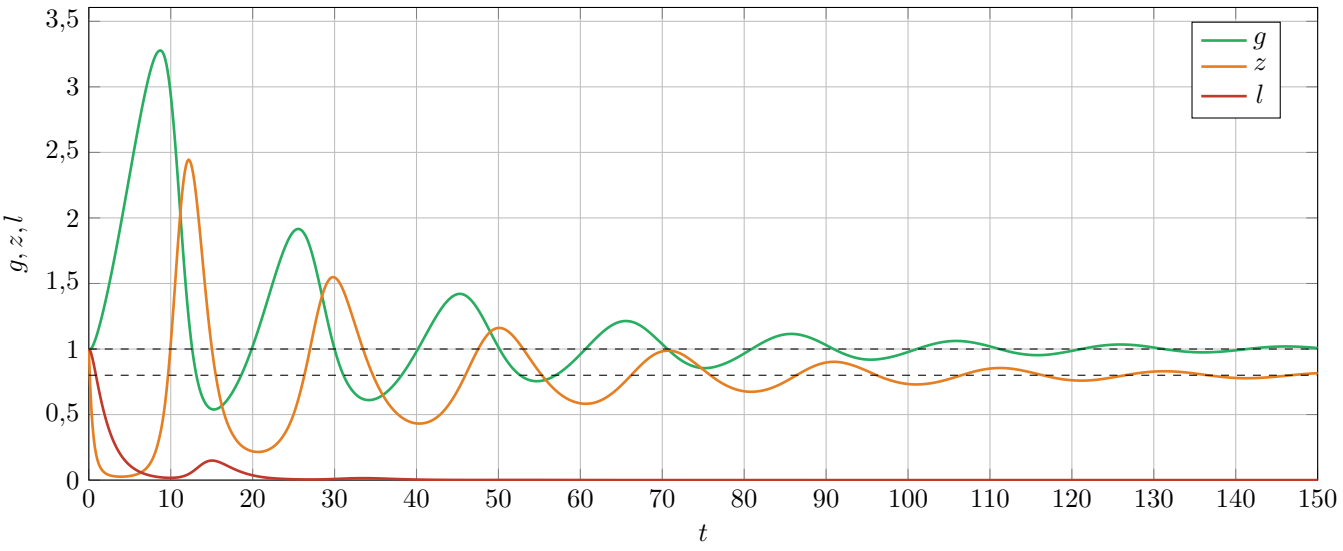
$$\dot{g} = rg\left(1 - \frac{g}{g_{\max}}\right) - \chi g z \tag{45}$$

$$\dot{z} = \eta z\left(\frac{g}{g_{\max}} - l - d\right) \tag{46}$$

Z d smo vpeljali umrljivost zajcev, r rast trave, χ pa vpliv zajcev na travo Poleg trivialnega stacionarnega stanja brez populacij in samo s travo ($g = g_{\max}$), poiščemo še koeksistenčno stanje: $g = g_{\max}(1 - \chi/r), z = 1, l = (1 - \chi/r) - d$, pogoj je seveda $\chi/r < 1 - d$. Imamo še možno koeksistenco trave in zajcev brez lisic, kar je podobno primeru omejene populacije zajcev (brez trave).



Graf 23: Primer koeksistence vseh treh populacij ($\chi = 0{,}3; r = 1{,}0; d = 0{,}2; g_{\max} = 5{,}0; \eta = 2{,}0$).



Graf 24: Primer koeksistence trave in zajcev, saj zaradi prepočasne rasti trave v začetku lisice pojedo skoraj vse zajce, kar je sanje usodno ($\chi = 0{,}3; r = 0{,}3; d = 0{,}2; g_{\max} = 5{,}0; \eta = 2{,}0$).

Koeksistenca zajcev in trave: $g = g_{\max} d, z = (1 - d)r/\chi$. Primera, ko izumrejo tako lisice kot zajci, ne bomo risali, saj se trava enostavno dvigne do $g_{\max}$, kar je trivialno stacionarno stanje.

3 Laser

Laser modeliramo s številom vzbujenih atomov A in številom fotonov F v resonatorju. Vzbujeni atomi lahko izsevajo nove fotone, ali pa spontano razpadejo, medtem ko se fotoni lahko izgubljajo. Atome na novo vzbujamo z R:

$$\dot{F} = -\alpha F + \beta_1 AF \tag{47}$$

$$\dot{A} = -\beta_0 A - \beta_2 AF + R \tag{48}$$

Privzamemo $\beta_1 = \beta_2$ in uvedemo brezdimenzijske spremenljivke: $t \to t\sqrt{\alpha\beta_0}$, $a = \beta_0 A/\alpha$, $f = \beta_1 F/\beta_0$, $p = \sqrt{\beta_0/\alpha}$, $\mathcal{R} = BR/\sqrt{\alpha^3\beta_0}$:

$$\dot{f} = \frac{f}{p}(a-1) \tag{49}$$

$$\dot{a} = \mathcal{R} - pa(1+f) \tag{50}$$

Tokrat nimamo trivialne rešitve z ničnima populacijama, saj je črpanje konstantno. Ena možnost je, da nimamo fotonov ($f = 0$), populacija vzbujenih atomov pa je potem $a = \mathcal{R}/p$. Druga je stabilno stanje z obema populacijama: $a = 1$ in $f = \mathcal{R}/p - 1$. Jacobian je:

$$\begin{bmatrix} \frac{\mathcal{R}-p}{p^2} & 0 \\ -\mathcal{R} & -p \end{bmatrix} \quad \leftarrow \quad \begin{bmatrix} \frac{a-1}{p} & \frac{f}{p} \\ -pa & -p(1+f) \end{bmatrix} \quad \rightarrow \quad \begin{bmatrix} 0 & \frac{\mathcal{R}-p}{p^2} \\ -p & -\mathcal{R} \end{bmatrix} \tag{51}$$

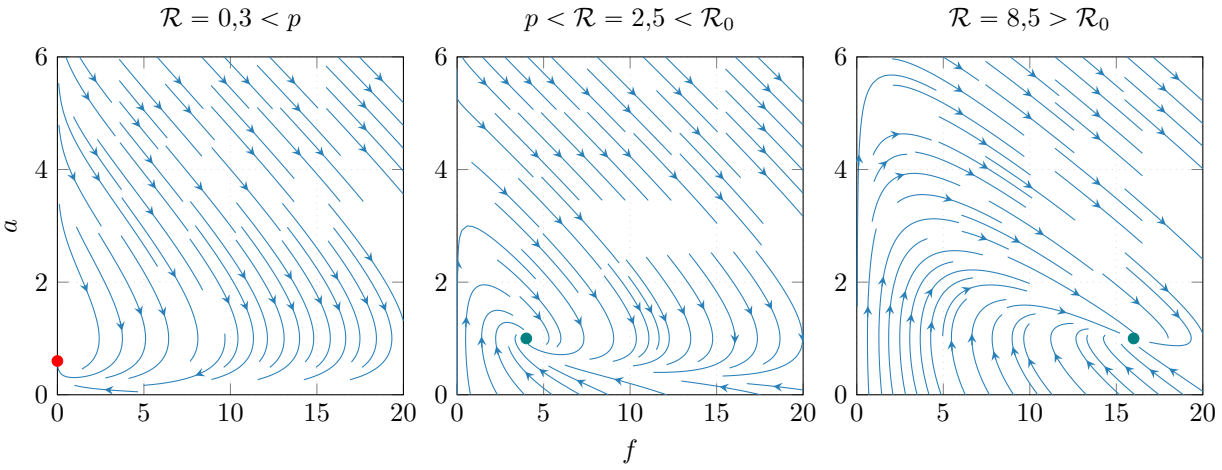
Lastne vrednosti prvega stacionarnega stanja $-p$ in $(\mathcal{R}-p)/p^2$. Prva je vedno negativna (tudi če ni fotonov, vzbujeni atomi spontano razpadajo s hitrostjo $-p$), slednja je za prešibko črpanje ($\mathcal{R} < p$) negativna, za večje pa pozitivna. Ker je to stacionarno stanje brez fotonov, je $\mathcal{R} = p$ meja za vklop laserja, ta lastna vrednost pa pove, kolikšna je začetna rast populacije fotonov.

Lastne vrednosti drugega stacionarnega stanja pa so

$$\frac{-\mathcal{R} \pm \sqrt{\mathcal{R}^2 - 4\frac{\mathcal{R}-p}{p}}}{2}. \tag{52}$$

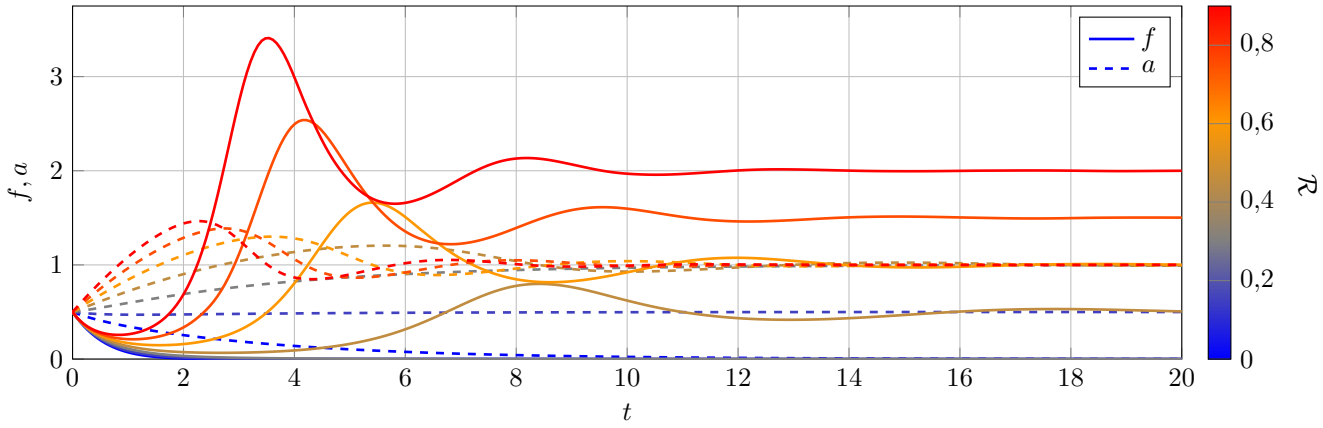
Ker mora biti $f \geqslant 0$, velja $\mathcal{R} \geqslant p$. Ob tem pogoju sta obe lastni vrednosti nepozitivni (vrednost pod korenom je manjša ali enaka $\mathcal{R}^2$). Če je izraz pod koreno negativen, dobimo kompleksni del, ki predstavlja kotno frekvenco nihanja okoli stacionarnega stanja, medtem ko realni del predstavlja dušenje. Meja med režimoma z oscilacijo in brez je pri

$$\mathcal{R}_0 = \frac{2 + 2\sqrt{1-p^2}}{p} \tag{53}$$



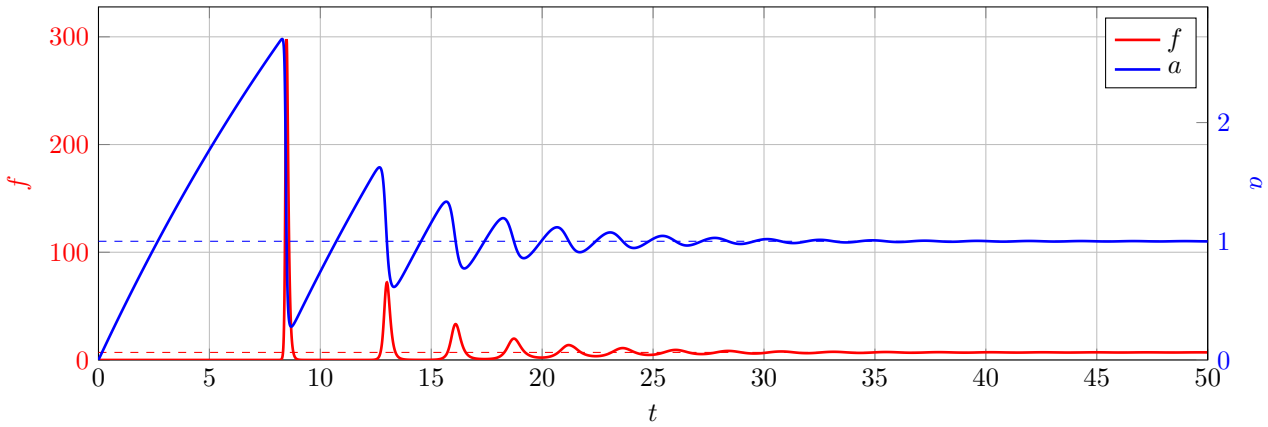
Graf 25: Fazni diagrami za vse tri režime ($p = 0{,}5$).

Primer $p < \mathcal{R} < \mathcal{R}_0$ se od drugih dveh razlikuje po tem (črte na faznem diagramu se zavijejo proti stacionarnemu stanju), da se stacionarnemu stanju približamo z oscilacijami, medtem ko se za $\mathcal{R} > \mathcal{R}_0$ približamo le z enim nihajem (črta pride direktno v stacionarno stanje).



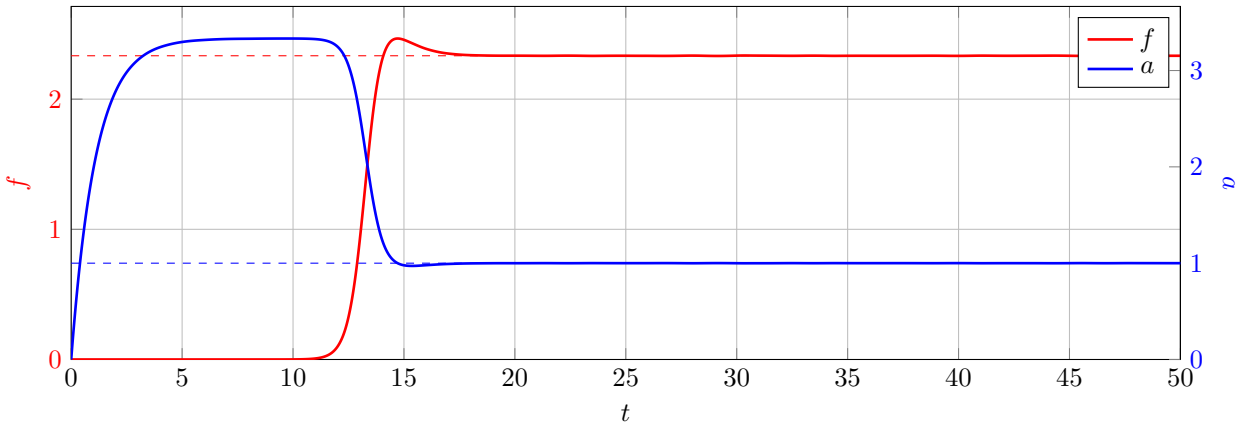
Graf 26: Primeri za prehod $\mathcal{R}$ čez mejo $p = 0{,}3$ (siva).

Z naraščanjem črpanja se najprej na višji nivo (1) dvigne populacija vzbujenih atomov, ko pa je črpanje nad mejo, se začnejo pojavljati tudi fotoni, ki se ustaljujejo na višjih nivojih (odvisno od črpanja).



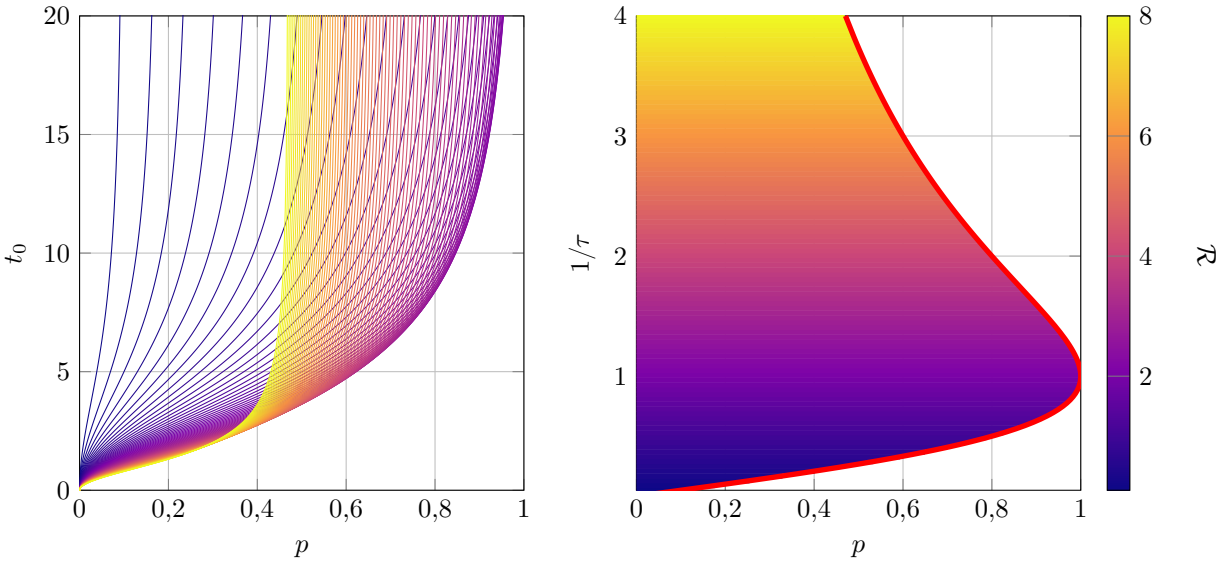
Graf 27: Zagon laserja za primer $p = 0{,}1$ in $\mathcal{R} = 0{,}3$.

Pri tako ekstremnem primeru oscilacije sprva niso dušen sinus, saj je amplituda prevelika.



Graf 28: Zagon laserja za primer $p = 0{,}9$ in $\mathcal{R} = 3{,}0$.

V tem primeru ni oscilacij, ampak se populaciji vzbujenih atomov in fotonov približata stacionarnemu stanju z enim nihajem.



Graf 29: Perioda majhnih nihanj okoli ravnovesnega stanja laserja in (maksimalen) koeficient dušenja za r in p. Ker nimamo pri vseh kombinacijah nihanja, niso narisane vse vrednosti, mejo dovoljenih kombinacij označuje rdeča črta.

Z večanjem p perioda oscilacij očitno narašča, medtem ko je koeficient dušenja neodvisen. Po drugi strani perioda ni monotona funkcija $\mathcal{R}$. Za kompletnost zapišimo še mejo kombinacij parametrov, kjer se še pojavi nihanje:

$$p_{\max} = \frac{4\mathcal{R}}{4 + \mathcal{R}^2} \tag{54}$$

4 Zaključek

V nalogi smo dokaj podrobno raziskali model epidemije, ga nadgradili z več stadiji, cepljenjem in zakasnjenimi stadiji ter opazovali vplive posameznih parametrov na potek epidemije in končno kompozicijo populacije. V drugem delu smo raziskali tudi model populacij zajcev in lisic, ki smo ga z nadgradnjami poskušali narediti bolj realističnega. Za konec smo raziskali še osnovni model laserja.

5 Uporabljena orodja

- Python 3.13 za reševanje sistemov navadnih diferencialnih enačb z začetnimi pogoji (`scipy.integrate.solve_ivp`) in risanje grafov;
- tikzplot42 (lastna odprta knjižnica za Python) za enostavno risanje LaTeX grafov;
- Google Gemini (Flash 3.6) za preverjanje besedila in iskanje morebitnih tipkarskih napak (popravki so bili nato narejeni ročno, zato je besedilo v celoti človeško delo) ter za pospešitev pisanja ponavljajoče se kode za risanje in stilizacijo grafov.